

Estatística e Probabilidade

Material esquematizado e comentado de todo o conteúdo programático
Edital nº 1 – SEFAZ/AL, de 24 de agosto de 2026 · Banca CEBRASPE
Prova objetiva P1 · 10 itens · Julgamento CERTO/ERRADO · Aplicação em
20/12/2026

Item 1 e 2 do edital · Estatística descritiva e análise exploratória de dados

Item 2.1 · Gráficos, diagramas, tabelas e medidas descritivas

Item 3, 3.1 e 3.2 · Probabilidade, axiomas, condicional e independência

Item 4 e 4.1 · Amostragem aleatória simples, estratificada, sistemática e por conglomerados

Base empírica. O conteúdo foi calibrado sobre o acervo oficial do CEBRASPE: foram baixados e processados **582 arquivos** (291 cadernos de provas objetivas e 291 gabaritos definitivos) de **46 concursos**, varridos automaticamente em busca dos blocos de Estatística e Probabilidade. Foram localizados e analisados item a item **11 blocos**, com **62 questões** — **50 no formato certo/errado** e 12 de múltipla escolha —, todas conferidas contra o gabarito definitivo e recalculadas de forma independente.

Fonte do conteúdo programático e das regras de pontuação. Itens 8.2, 8.11 e 14.2.3 e Anexo I do Edital nº 1 – SEFAZ/AL, de 24 de agosto de 2026 (CEBRASPE).

0.1 O que o edital pede — e o que ele *não* pede

O conteúdo programático de Estatística e Probabilidade está no item 14.2.3 do edital e é curto. Reproduzido literalmente, com a numeração original:

EDITAL Nº 1 – SEFAZ/AL, DE 24 DE AGOSTO DE 2026 — ITEM 14.2.3

ESTATÍSTICA E PROBABILIDADE: 1 Estatística descritiva. 2 Análise exploratória de dados. 2.1 Gráficos, diagramas, tabelas, medidas descritivas (posição, dispersão, assimetria e curtose). 3 Probabilidade. 3.1 Definições básicas e axiomas. 3.2 Probabilidade condicional e independência. 4 Amostragem. 4.1 Amostragem aleatória simples, estratificada, sistemática e por conglomerados.

Cada um desses oito rótulos vira um bloco deste material. O mapa de leitura é o seguinte:

ITEM DO EDITAL	ONDE ESTÁ NESTE MATERIAL	PÁGINAS APROX.
1 · Estatística descritiva	Seções 1.1 a 1.3 — o que é a disciplina, tipos de variável, séries e tabelas	—
2 · Análise exploratória de dados	Seções 1.4 e 1.11 — a lógica exploratória, gráficos e boxplot	—
2.1 · Gráficos, diagramas, tabelas	Seções 1.3 e 1.4	—
2.1 · Medidas de posição	Seções 1.6 e 1.7 — média, mediana, moda e separatrizes	—
2.1 · Medidas de dispersão	Seção 1.8	—
2.1 · Assimetria e curtose	Seções 1.9 e 1.10	—
3 · Probabilidade / 3.1 · Definições e axiomas	Seções 2.1 a 2.4	—
3.2 · Condicional e independência	Seções 2.5 a 2.8	—
4 · Amostragem / 4.1 · As quatro técnicas	Seções 3.1 a 3.10	—

As três leituras decisivas do programa

Primeira: não há inferência. Não constam estimação por intervalo de confiança, testes de hipótese, regressão, distribuições de probabilidade nominadas (binomial, Poisson, normal, t de Student) nem teorema do limite central. Isso reduz drasticamente o volume de estudo em relação a um edital fiscal típico — é a diferença entre estudar 30 horas e estudar 150. Se um item da prova mencionar "nível de significância", " p -valor" ou "intervalo de confiança de 95%", ele está fora do programa e provavelmente será anulado por recurso; mas **não conte com isso**: o edital admite, no item 14.1.2, que "cada item das provas poderá contemplar mais de um objeto de avaliação", e um conceito de amostragem pode vir embrulhado em linguagem de inferência.

Segunda: assimetria e curtose estão escritas com todas as letras. São os dois tópicos que o candidato médio pula — porque quase nenhum curso preparatório os aprofunda e porque parecem "avançados". Não são: cada um se resolve com

uma tabela de três linhas e um coeficiente. Justamente por serem pouco estudados, rendem item certo para quem os domina.

Terceira: amostragem tem peso desproporcional. Quatro técnicas nominadas em um programa de quatro linhas é sinal explícito de cobrança. E, no acervo analisado, a banca cobra mesmo: **27% dos itens**. Mais do que isso, a cobrança é sempre do mesmo jeito — descreve-se um plano amostral em linguagem administrativa e pergunta-se qual é a técnica.

0.2 A aritmética exata da prova — e o que ela obriga você a fazer

Esta seção não é digressão: ela determina quantos itens você deve marcar. O edital é explícito.

ITEM 8.2 — O FORMATO

"Cada prova objetiva será constituída de **itens para julgamento**, agrupados por comandos que deverão ser respeitados. O julgamento de cada item será **CERTO ou ERRADO** (...) o campo designado com o código C, que deverá ser preenchido pelo candidato caso julgue o item CERTO, e o campo designado com o código E, (...) caso julgue o item ERRADO."

ITEM 8.11.2 — A PONTUAÇÃO

A nota em cada item da P1 será igual a $60 \div (60 - np_1)$ ponto se a resposta concordar com o gabarito definitivo; $60 \div (60 - np_1)$ ponto negativo se discordar; e **0,00 ponto** caso não haja marcação ou haja marcação dupla — em que np_1 é o número de itens com gabarito alterado.

Três consequências que precisam ser internalizadas antes de abrir o conteúdo:

1. **O peso do erro é idêntico ao peso do acerto.** Não é "um terço", não é "meio ponto": é o mesmo valor, com sinal invertido. Na prática, a nota da disciplina é $A - E$ (acertos menos erros), medida em itens líquidos.
2. **Deixar em branco vale exatamente zero** — nem penaliza nem premia. Isso torna o branco uma jogada *neutra*, e não uma derrota.
3. **Um chute simétrico tem valor esperado nulo.** Com 50% de chance de acerto, o ganho esperado é $0,5(+1) + 0,5(-1) = 0$. Marcar só compensa quando sua confiança supera 50% — e, considerando que a percepção de confiança costuma ser otimista, a régua prática é **marcar acima de ~65%**.

POR QUE 7 ACERTOS PODEM VALER MAIS QUE 10 MARCAÇÕES

Candidato A — marca os 10 itens, acerta 7 e erra 3. Nota líquida: $7 - 3 = 4$.

Candidato B — marca 7 itens (os que domina), acerta 7 e deixa 3 em branco. Nota líquida: $7 - 0 = 7$.

Mesmo conhecimento, **75% a mais de pontuação**. A diferença é inteiramente estratégica. Em uma prova em que dez pontos separam centenas de candidatos, isso decide aprovação.

A nota mínima que você precisa atingir

O item 8.11.4 define os cortes: $N_1 = (60 - np_1) \times 0,2$, $N_2 = (100 - np_2) \times 0,3$ e $N_3 = (160 - n_T) \times 0,3$, desprezada a parte não inteira. Sem anulações, isso significa:

PROVA	ITENS	NOTA MÍNIMA	EQUIVALE A
P1 — Conhecimentos básicos	60	12	12 itens líquidos (20%)
P2 — Conhecimentos específicos	100	30	30 itens líquidos (30%)
Conjunto P1 + P2	160	48	48 itens líquidos (30%)

Reprovação em qualquer um dos três cortes elimina o candidato. Note a assimetria: a P1 exige apenas 20% de aproveitamento líquido, mas o conjunto exige 30% — de modo que um desempenho fraco na P1 precisa ser compensado na P2. Sete itens líquidos em Estatística representam **quase 60% do corte inteiro da P1**.

Onde a disciplina entra na prova

PROVA	DISCIPLINA	ITENS	% DA PROVA
P1 — Conhecimentos básicos (60 itens)	Matemática Financeira	5	8,3%
	Direito Constitucional	5	8,3%
	Direito Administrativo	5	8,3%
	Contabilidade Geral	5	8,3%
	Direito Tributário	10	16,7%
	Estatística e Probabilidade	10	16,7%
	Contabilidade Pública	10	16,7%
	Economia	10	16,7%
	Total	60	100%

Estatística e Probabilidade responde por **1/6 da P1** — mesmo peso de Direito Tributário, Contabilidade Pública e Economia, e **o dobro** de Direito Administrativo, Constitucional, Contabilidade Geral e Matemática Financeira. Como o programa é fechado e a matemática exigida é elementar, é a disciplina de melhor relação ponto por hora de estudo de todo o edital.

0.3 Mapa de incidência: o que o CEBRASPE realmente cobra

Os onze blocos de Estatística localizados no acervo oficial, com a distribuição dos 62 itens pelos eixos do programa de Alagoas:

CONCURSO / ANO	BLOCO	FORMATO	ITENS	DESCR.	PROB.	AMOSTR.
BCB 2024 — Analista	Itens 26–35	C/E	10	6	4	—
SUSEP 2025 — Analista	Itens 11–20	C/E	10	5	5	—
SEFAZ/RJ 2025 — Auditor	Q. 54–60	A–E	7	3	2	2
CGE/RJ 2023 — Auditor	Itens 37–42	C/E	6	3	—	3
ANA 2024 — Especialista	Itens 16–20	C/E	5	—	5	—
TCE/RN 2025 — Auditor	Itens 71–75	C/E	5	—	—	5
SEFAZ/RN 2025 — Auditor	Q. 51–55	A–E	5	2	1	1
TC/DF 2024 — Auditor	Itens 28–31	C/E	4	4	—	—
SEEC/DF 2019 — Auditor Fiscal	Itens 74–77	C/E	4	4	—	—
ANEEL 2025 — Especialista	Itens 7–9	C/E	3	—	—	3
TC/DF 2020 — ACE	Itens 60–62	C/E	3	—	—	3
Total			62	27	17	17
Participação			100%	44%	27%	27%

Um item do SEFAZ/RN 2025 (ANOVA) ficou fora dos três eixos por ser inferência — assunto que **não** consta do programa de Alagoas. Ele é o único dos 62 que não se encaixa neste edital, o que confirma a estabilidade do recorte que a banca vem praticando.

O QUE ESSE MAPA AUTORIZA A CONCLUIR

- **Projeção para os 10 itens:** aproximadamente **4 de descritiva**, **3 de probabilidade** e **3 de amostragem**. Estude nessa proporção.
- Em **descritiva**, o CEBRASPE quase nunca pede cálculo pesado. Pede a *classificação* da medida (posição × dispersão × forma), uma *comparação* (média × mediana), ou uma conta de uma linha. O erro típico do candidato é conceitual, não aritmético.
- Em **probabilidade**, três estruturas concentram praticamente tudo: **condicional**, **independência** e **probabilidade total**. Bayes aparece disfarçado ("sabendo que o candidato foi aprovado, qual a probabilidade de...").
- Em **amostragem**, o padrão é quase invariável: descreve-se um plano em linguagem administrativa e pergunta-se qual técnica é. Distinguir **estratificada de conglomerados** vale, sozinho, vários itens — no TCE/RN 2025, essa única distinção decidia cinco itens seguidos.

0.4 A estrutura "afirmação + justificativa"

É a construção predileta do CEBRASPE em Estatística e o campeão absoluto de erros. O item traz duas proposições ligadas por um conectivo causal — *pois, já que, uma vez que, visto que, porque* — e o candidato julga apenas a primeira.

EXEMPLO REAL — TCE/RN 2025, ITEM 72

"O procedimento descrito caracteriza uma amostragem por conglomerados, **pois** foram selecionados grupos específicos de obras para compor a amostra."

Parte 2 (justificativa): verdadeira — grupos específicos foram, de fato, selecionados.

Parte 1 (conclusão): falsa — o plano descrito é *estratificado*, não por conglomerados.

Resultado: item **ERRADO**. Quem leu só a segunda metade, que soa incontestável, marcou CERTO e perdeu dois itens de uma vez (o errado e o certo que ele anula).

A regra operacional é rígida: **um item só é CERTO se todas as suas partes forem verdadeiras e o nexos entre elas se sustentar**. Três verificações, nesta ordem: (i) a conclusão é verdadeira? (ii) a justificativa é verdadeira? (iii) a justificativa realmente sustenta a conclusão? Qualquer "não" torna o item errado.

0.5 Como usar este material

1. **Primeira leitura, sequencial.** Leia cada tópico inteiro, sem pular as caixas — elas concentram exatamente o que a banca transforma em item. Os **exemplos resolvidos** (borda verde) devem ser refeitos com lápis e papel; ler passivamente não fixa procedimento de cálculo.
2. **Segunda passagem, pelas questões.** Resolva os blocos de questões comentadas **antes** de ler o comentário. São questões reais, com gabarito definitivo conferido; várias trazem a *justificativa oficial do CEBRASPE*, transcrita e identificada como tal.
3. **Revisão, pela Parte 4.** Formulário completo, as 40 frases que valem ponto, o radar de palavras e o método de resolução em quatro passos. Na véspera, leia apenas isso.

TÓPICO 1 · ESTATÍSTICA DESCRITIVA E ANÁLISE EXPLORATÓRIA DE DADOS

Corresponde aos itens 1, 2 e 2.1 do programa: "Estatística descritiva. Análise exploratória de dados. Gráficos, diagramas, tabelas, medidas descritivas (posição, dispersão, assimetria e curtose)."

1.1 O que é estatística descritiva — e por que a distinção importa

A Estatística divide-se em dois grandes ramos, e o edital de Alagoas cobra **apenas o primeiro**:

	ESTATÍSTICA DESCRITIVA	ESTATÍSTICA INFERENCIAL
O que faz	Organiza, resume e apresenta os dados efetivamente observados	Generaliza da amostra para a população, com margem de erro
Alcance das conclusões	Restrito ao conjunto observado	Estende-se à população não observada
Ferramentas	Tabelas, gráficos, média, desvio padrão, quartis	Intervalos de confiança, testes de hipótese, regressão
Incerteza	Não há — descreve-se o que se viu	É o objeto central — quantifica-se o erro da generalização
Consta do edital de AL?	Sim (itens 1 e 2)	Não

Essa fronteira já foi objeto de item: descrever que "a média amostral observada foi 28" é descritiva; afirmar que "a média populacional está entre 26 e 30 com 95% de confiança" é inferência. O CEBRASPE gosta de misturar as duas linguagens no mesmo enunciado.

As fases do método estatístico

Vocabulário clássico, ocasionalmente cobrado em item conceitual:

1. **Definição do problema** — o que se quer conhecer e sobre qual população.
2. **Planejamento** — como coletar: censo ou amostra, qual técnica, qual instrumento.
3. **Coleta de dados** — *direta* (o pesquisador obtém do objeto: declarações do contribuinte, registros administrativos) ou *indireta* (deduzida de outra coleta). A coleta direta subdivide-se em *contínua* (registro permanente, como emissão de NF-e), *periódica* (censo decenal) e *ocasional*.
4. **Crítica dos dados** — busca de inconsistências. Crítica *externa* (falhas de origem: erro de digitação, campo em branco) e *interna* (coerência entre variáveis: despesa maior que receita).
5. **Apuração** — soma, contagem, tabulação.
6. **Exposição** — tabelas e gráficos.
7. **Análise e interpretação** — leitura substantiva dos resultados.

O que é "análise exploratória de dados" (item 2 do edital)

A **AED** (ou EDA, *exploratory data analysis*), formulada por John Tukey nos anos 1970, é uma postura antes de ser um conjunto de técnicas: **olhar os dados antes de modelá-los**. Em vez de partir de uma hipótese e testá-la, deixa-se que os dados sugiram estrutura, padrões, assimetrias e valores atípicos.

As ferramentas típicas da AED — e é essa a lista que o edital tem em mente — são o **boxplot**, o **ramo-e-folhas**, o **histograma**, o **diagrama de dispersão** e as **medidas resistentes** (mediana, AIQ), preferidas às medidas clássicas justamente porque não se deixam contaminar por outliers.

POR QUE A AED PREFERE MEDIANA E AIQ

São medidas **resistentes** (ou robustas): uma única observação absurdamente grande desloca a média e infla o desvio padrão, mas não altera a mediana nem a distância entre quartis. Em auditoria fiscal, em que outliers são a regra (uma nota de R\$ 40 milhões no meio de milhares de R\$ 2 mil), essa propriedade é operacionalmente decisiva — e é exatamente a razão pela qual a banca de um concurso fiscal insere AED no programa.

1.2 Tipos de variável e escalas de mensuração

Toda questão de descritiva começa aqui, porque **a natureza da variável determina qual medida e qual gráfico são admissíveis**. É a fonte mais barata de item errado da banca.

TIPO	SUBTIPO	EXEMPLO FISCAL	MEDIDAS CABÍVEIS	GRÁFICO TÍPICO
Qualitativa (categórica)	Nominal — categorias sem ordem	Regime tributário (Simples, lucro presumido, lucro real); município do contribuinte; CNAE	Só moda	Barras, setores, Pareto
	Ordinal — categorias com ordem	Porte da empresa (micro, pequena, média, grande); grau de risco fiscal (baixo, médio, alto)	Moda e mediana	Barras ordenadas
Quantitativa (numérica)	Discreta — resulta de contagem; assume valores isolados	Nº de notas fiscais emitidas; nº de autuações; nº de filiais	Todas	Bastões, barras
	Contínua — resulta de mensuração; assume qualquer valor de um intervalo	Valor do ICMS recolhido; faturamento; alíquota efetiva	Todas	Histograma , boxplot

As quatro escalas de mensuração (Stevens)

Refinamento da classificação acima, ocasionalmente cobrado:

ESCALA	PERMITE	ZERO É ABSOLUTO?	EXEMPLO
Nominal	Só identificar e contar (=, ≠)	não se aplica	Regime tributário
Ordinal	Ordenar (<, >), mas não medir distâncias	não se aplica	Grau de risco fiscal
Intervalar	Somar e subtrair; a distância é significativa	Não — o zero é convencional	Temperatura em °C; ano-calendário
Razão	Todas as operações, inclusive razões ("o dobro de")	Sim — zero significa ausência	Faturamento; ICMS recolhido; idade

A distinção intervalar × razão explica por que **não se calcula coeficiente de variação para temperatura em graus Celsius**: o CV é uma razão entre desvio padrão e média, e só faz sentido quando a média está em escala de razão, com zero absoluto. É uma sutileza pouco cobrada, mas que já apareceu.

QUATRO ARMADILHAS DE CLASSIFICAÇÃO

- **Número não é sinônimo de quantitativa.** CNPJ, CEP, código de município e número de inscrição são variáveis *nominais* ainda que escritas com algarismos. Não têm média, não têm desvio padrão.
- **Ordinal não vira quantitativa por receber nota.** Atribuir 1, 2 e 3 a "baixo, médio e alto" não autoriza calcular média: a distância entre "baixo" e "médio" não é conhecida nem necessariamente igual à distância entre "médio" e "alto".
- **Média não se aplica a qualitativa**, nem nominal nem ordinal. Já a **moda existe sempre**, para qualquer tipo de variável — é a única medida universal. Item que ofereça "a média da variável *qualidade do serviço*" é ERRADO por construção.
- **Discreta pode ter média fracionária.** "2,3 filhos por mulher" e "1,7 autuação por fiscal" são médias legítimas de variáveis discretas — a média **não precisa ser um valor observável**.

1.3 Tabelas, séries estatísticas e distribuições de frequência

1.3.1 Séries estatísticas

Uma **série** é a apresentação tabular de dados segundo um critério. A classificação clássica usa três elementos — **tempo**, **local** e **fenômeno** — e varia conforme qual deles muda:

SÉRIE	O QUE VARIA	EXEMPLO
Temporal (cronológica, histórica)	Tempo	Arrecadação de ICMS em Alagoas, 2020 a 2026
Geográfica (territorial)	Local	Arrecadação de ICMS por município, em 2026
Específica (categórica)	Fenômeno	Arrecadação por setor econômico, em Alagoas, 2026
Mista (tabela de dupla entrada)	Dois ou mais elementos	Arrecadação por município e por ano
Distribuição de frequências	Os valores da própria variável	Nº de contribuintes por faixa de faturamento

1.3.2 Elementos de uma distribuição de frequências

Dada uma variável observada n vezes, a distribuição organiza os resultados em colunas que a banca mistura de propósito:

SÍMBOLO	NOME	DEFINIÇÃO	FECHA EM
f_i	Frequência absoluta simples	Quantas vezes a classe ocorreu	n
F_i	Frequência absoluta acumulada	$f_1 + f_2 + \dots + f_i$	n , na última classe
fr_i	Frequência relativa	f_i / n	1 (ou 100%)
Fr_i	Frequência relativa acumulada	soma das relativas até a classe i	1 (ou 100%)

Para dados agrupados em **classes** (intervalos), quatro definições precisam estar automatizadas:

- **Limites** — a notação $20 \mid - 30$ significa "inclui 20, exclui 30". O elemento que vale exatamente 30 pertence à classe seguinte.
- **Amplitude da classe** h = limite superior – limite inferior. Em geral todas as classes têm a mesma amplitude, mas **não obrigatoriamente**.
- **Ponto médio** (marca de classe) x_i = (limite inferior + limite superior)/2. É o valor que *representa* toda a classe nos cálculos de média e variância — o que introduz um erro de agrupamento, pois supõe que os dados se distribuem

uniformemente dentro da classe.

- **Amplitude total** = maior limite superior – menor limite inferior.

1.3.3 Quantas classes usar — a regra de Sturges

$$k = 1 + 3,322 \cdot \log_{10}(n)$$

Número aproximado de classes para n observações; arredonda-se para o inteiro mais próximo

Para $n = 100$, $k = 1 + 3,322 \times 2 \approx 7,6$, ou seja, 7 ou 8 classes. A regra é orientativa, não obrigatória — e a banca costuma cobrá-la apenas na forma "existe uma regra empírica que relaciona o número de classes ao tamanho da amostra" (CERTO).

EXEMPLO MESTRE — A TABELA QUE ATRAVESSA TODO O TÓPICO 1

Distribuição do ICMS recolhido por 100 contribuintes de um segmento, em R\$ mil. **Esta mesma tabela será reutilizada em todas as seções seguintes** — média, mediana, moda, quartis, dispersão, assimetria e curtose —, de modo que você veja todas as medidas nascendo do mesmo conjunto de dados.

CLASSE (R\$ MIL)	F_i	X_i (PONTO MÉDIO)	F_i (ACUM.)	FR_i	FR_i (ACUM.)
0 — 10	5	5	5	5%	5%
10 — 20	15	15	20	15%	20%
20 — 30	40	25	60	40%	60%
30 — 40	25	35	85	25%	85%
40 — 50	15	45	100	15%	100%
Total	100	—	—	100%	—

Leitura imediata: a classe modal (maior f_i) é 20 |— 30; $h = 10$ em todas as classes; a amplitude total é $50 - 0 = 50$.

COMO SE LÊ A ACUMULADA — O ATALHO QUE RESOLVE MEDIANA E QUARTIS SEM FÓRMULA

A frequência **relativa acumulada** é a régua das separatrizes. Onde a acumulada cruza **25%** está o Q_1 ; **50%**, a mediana; **75%**, o Q_3 ; **90%**, o percentil 90. Na tabela acima: a acumulada vale 20% ao fim da segunda classe e 60% ao fim da terceira — logo **tanto Q_1 quanto a mediana caem na classe 20 |— 30**, e o Q_3 (75%) cai em 30 |— 40. Questão que apresenta gráfico ou tabela de acumuladas é, quase sempre, questão de separatriz disfarçada.

1.4 Gráficos e diagramas

GRÁFICO	PARA QUE SERVE	DETALHE TÉCNICO	COMO A BANCA ERRA DE PROPÓSITO
Histograma	Quantitativa contínua agrupada em classes	Barras justapostas , sem espaço entre elas — a continuidade do eixo é o ponto	Chamar de histograma o gráfico de barras de variável qualitativa
Gráfico de barras / colunas	Qualitativa ou quantitativa discreta	Barras separadas ; a ordem pode ser arbitrária em variável nominal	Trocar por histograma; ou afirmar que a ordem das barras é obrigatória
Gráfico de setores ("pizza")	Composição — partes de um todo	Cada setor é proporcional à frequência relativa; o total é sempre 100%	Usar para série temporal; ou para variável com muitas categorias

GRÁFICO	PARA QUE SERVE	DETALHE TÉCNICO	COMO A BANCA ERRA DE PROPÓSITO
Polígono de frequências	Forma da distribuição	Une os pontos médios do topo das barras do histograma	Confundir com a ogiva
Ogiva (polígono acumulado)	Frequências acumuladas	É sempre não decrescente ; parte de zero e termina em n (ou 100%)	Afirmar que pode decrescer em algum trecho
Ramo-e-folhas	Forma da distribuição preservando os dados originais	Cada linha é um "ramo" (dezena) e as folhas são as unidades	Dizer que perde a informação individual — isso é o histograma
Boxplot	Resumo de cinco números; comparação entre grupos	Exibe mínimo, Q_1 , mediana , Q_3 , máximo e outliers	Dizer que exibe a média
Diagrama de dispersão	Relação entre duas variáveis quantitativas	Cada ponto é um par (x, y)	Ler causalidade onde há apenas correlação
Diagrama de Pareto	Priorização — "poucos vitais, muitos triviais"	Barras em ordem decrescente + curva de frequência acumulada	Apresentar as barras fora de ordem
Cartograma	Distribuição geográfica	Mapa com intensidade proporcional ao valor	—

1.4.1 O histograma e o polígono de frequências da tabela mestre

Os dois gráficos abaixo são construídos com **exatamente** os números da tabela da seção 1.3.3. Vale percorrê-los coluna a coluna, comparando com a tabela: é essa tradução entre tabela e figura que a banca cobra quando apresenta um gráfico e pergunta pela mediana ou pela moda.

ICMS recolhido por 100 contribuintes — histograma e polígono de frequências


frequência absoluta (nº de contribuintes) por classe de R\$ mil



Leitura. As barras são **justapostas** porque a variável é contínua — o eixo não tem buracos. O polígono liga os **pontos médios** do topo das barras e é o que revela a forma: subida rápida até a terceira classe e descida mais lenta, ou seja, uma cauda mais longa à direita — **assimetria positiva**, confirmada depois pelos coeficientes da seção 1.9. Só a classe modal recebe rótulo; as demais frequências estão na tabela da seção 1.3.3.

A mesma distribuição em ogiva — e como ela entrega os quartis

frequência relativa acumulada (%)



Leitura. A ogiva é o gráfico das **acumuladas** e, por isso, **nunca decresce**. Cada separatriz é lida na horizontal: entra-se pela altura desejada (25%, 50%, 75%), caminha-se até a curva e desce-se ao eixo. É a versão gráfica da fórmula de interpolação da seção 1.6.3 — e explica por que uma questão que traz "a figura apresenta as frequências relativas acumuladas" é, quase sempre, questão de quartil.

CLASSES DE AMPLITUDES DIFERENTES: A ÁREA É QUE REPRESENTA A FREQUÊNCIA

Quando o histograma tem classes de larguras distintas, a **altura** da barra deixa de ser a frequência e passa a ser a **densidade de frequência** (f_i / h_i). O que representa a frequência é a **área** do retângulo — base $\times$ altura. Ler a altura como frequência nesse caso é erro clássico, e desenhar barras de larguras diferentes com altura igual à frequência produz um gráfico visualmente enganoso, o que é justamente o ponto da regra.

COMO IDENTIFICAR A FORMA DA DISTRIBUIÇÃO PELO GRÁFICO

- **Simétrica:** o histograma é espelhado em torno do centro; média, mediana e moda coincidem.
- **Assimétrica à direita (positiva):** concentração de barras à **esquerda** e uma cauda longa à direita. É o padrão de renda, faturamento e valor de nota fiscal.
- **Assimétrica à esquerda (negativa):** concentração à **direita**, cauda longa à esquerda. É o padrão de notas em prova fácil ou de idade de aposentadoria.
- **Bimodal:** dois picos — quase sempre sinal de que o conjunto mistura duas populações distintas (ex.: contribuintes do Simples e do lucro real na mesma tabela).

1.5 Panorama das medidas descritivas

Antes de entrar nas fórmulas, fixe a **taxonomia**. Ela sozinha resolve vários itens do CEBRASPE, que costuma perguntar não o valor da medida, mas a que família ela pertence.

FAMÍLIA	RESPONDE À PERGUNTA	MEDIDAS
Posição (tendência central)	"Em torno de que valor os dados se concentram?"	Média (aritmética, geométrica, harmônica, ponderada), mediana, moda
Posição (separatrizes)	"Que valor deixa x% dos dados abaixo?"	Quartis, decis, percentis
Dispersão (variabilidade)	"Quão espalhados estão os dados?"	Amplitude total, amplitude interquartílica, desvio médio, variância, desvio padrão, coeficiente de variação
Forma	"Qual o formato da distribuição?"	Assimetria e curtose

A REGRA DE OURO DA CLASSIFICAÇÃO

Quartil isolado é posição; diferença entre quartis é dispersão. Média é posição; desvio em torno da média é dispersão. Assimetria e curtose **nunca** são posição nem dispersão — são forma. Essa única linha já decidiu questão inteira (SEFAZ/RJ 2025, Q. 55) e é a chave da questão 54 da SEFAZ/RN 2025.

1.6 Medidas de posição — média, mediana e moda

1.6.1 Média aritmética

$$\text{simples: } \bar{x} = \frac{\sum x_i}{n} \quad \text{ponderada / agrupada: } \bar{x} = \frac{\sum f_i x_i}{\sum f_i}$$

Em dados agrupados em classes, x_i é o **ponto médio** da classe

CÁLCULO NA TABELA MESTRE

Passo 1. Multiplique cada ponto médio pela frequência:

$$5 \times 5 = 25 \cdot 15 \times 15 = 225 \cdot 25 \times 40 = 1.000 \cdot 35 \times 25 = 875 \cdot 45 \times 15 = 675$$

Passo 2. Some: $25 + 225 + 1.000 + 875 + 675 = \mathbf{2.800}$

Passo 3. Divida por $n = 100$: $\bar{x} = 2.800/100 = \mathbf{R\$ 28 \text{ mil}}$

Propriedades cobradas literalmente pela banca:

- **A soma dos desvios em torno da média é zero:** $\sum (x_i - \bar{x}) = 0$. É por isso que não se usa a soma simples dos desvios como medida de dispersão — ela seria sempre nula, e daí a necessidade de elevar ao quadrado (variância) ou tomar o módulo (desvio médio).
- **A média minimiza a soma dos quadrados** dos desvios: $\sum (x_i - a)^2$ é mínima quando $a = \bar{x}$. Já a **mediana minimiza a soma dos módulos** $\sum |x_i - a|$. Item que troque as duas é **ERRADO** — e essa troca é frequente.
- **É sensível a valores extremos.** Um único outlier a desloca; a mediana e a moda, não. Essa é a razão de a média de renda ser sempre maior que a mediana de renda.
- **Transformação linear:** se $y = a + b \cdot x$, então $\bar{y} = a + b \cdot \bar{x}$. A média "acompanha" integralmente somas e multiplicações.
- Está sempre entre o mínimo e o máximo, mas **não precisa ser um valor observado** nem sequer possível (2,3 filhos por mulher).
- **Média de médias não é a média geral**, salvo se os grupos tiverem o mesmo tamanho. Para combinar grupos, use a média *ponderada* pelos tamanhos. Essa é uma pegadinha recorrente.

1.6.2 As outras médias — geométrica e harmônica

MÉDIA	FÓRMULA	QUANDO É A MEDIDA CORRETA
Aritmética	$\sum x_i / n$	Grandezas que se somam (valores, quantidades)
Geométrica	$\sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$	Grandezas que se multiplicam : taxas de crescimento, retornos, índices
Harmônica	$n / \sum (1/x_i)$	Grandezas inversas: velocidades médias, preço médio por unidade

Desigualdade das médias: harmônica $\leq$ geométrica $\leq$ aritmética

Com igualdade **apenas** quando todos os valores são iguais entre si

1.6.3 Mediana

Valor que ocupa a posição central do **rol** (dados ordenados), deixando 50% das observações abaixo e 50% acima. É **medida de posição** e, simultaneamente, a **segunda separatriz** ($Q_2 = D_5 = P_{50}$).

- **Dados brutos, n ímpar:** é o termo de ordem $(n + 1)/2$.
- **Dados brutos, n par:** é a **média aritmética dos dois termos centrais**, de ordens $n/2$ e $n/2 + 1$.
- **É robusta:** não se altera com outliers.
- **Existe para variável ordinal**, ao contrário da média.

EXEMPLO EM DADOS BRUTOS — TODA A DESCRITIVA À MÃO, SEM FÓRMULA DE CLASSE

Antes de enfrentar a interpolação, é indispensável saber resolver o caso simples: dados soltos, sem agrupamento. ICMS recolhido (R\$ mil) por 9 contribuintes: **12 · 18 · 15 · 40 · 22 · 18 · 27 · 31 · 18**.

Passo 1 — o rol. Ordene: 12 · 15 · **18 · 18 · 18** · 22 · 27 · 31 · 40. Nada em descritiva se faz antes disso.

Média. Soma = 201; $\bar{x} = 201/9 = 22,33$.

Mediana. $n = 9$ é ímpar → termo de ordem $(9 + 1)/2 = 5.º$. O 5.º valor do rol é **18**. (Se n fosse par, seria a média dos dois centrais.)

Moda. O valor 18 aparece três vezes → $Mo = 18$. Distribuição **unimodal**.

Forma. $Mo = 18 \leq Md = 18 < \bar{x} = 22,33$ → **assimetria positiva**. O responsável é o valor 40, que puxa só a média.

Quartis. Q_1 na posição $(9 + 1)/4 = 2,5$ → média do 2.º com o 3.º = $(15 + 18)/2 = 16,5$. Q_3 na posição $3(9 + 1)/4 = 7,5$ → $(27 + 31)/2 = 29$. **AIQ** = $29 - 16,5 = 12,5$.

Amplitude total. $40 - 12 = 28$.

Variância, pelo atalho. $\Sigma x^2 = 5.115$ → $E(X^2) = 568,33$; $\bar{x}^2 = 498,78$ → $\sigma^2 = 69,56$ (populacional) e $\sigma = 8,34$.

Amostral: $\Sigma(x - \bar{x})^2 = 626$ → $s^2 = 626/8 = 78,25$ e $s = 8,85$.

CV. $8,85/22,33 = 39,6\%$.

Outliers. $16,5 - 1,5(12,5) = -2,25$ e $29 + 1,5(12,5) = 47,75$. O máximo é 40 → **não há outlier**, embora 40 esteja visivelmente afastado. Repare: "*parecer atípico*" não basta — o critério é numérico.

UMA HONESTIDADE SOBRE QUARTIS EM DADOS BRUTOS

Existem várias convenções de posicionamento de quartis em dados não agrupados (a fórmula $(n+1)/4$ usada acima, a $n/4$, a interpolação linear dos softwares estatísticos), e elas produzem valores ligeiramente diferentes. **O CEBRASPE evita a controvérsia:** em dados brutos, costuma escolher n que caia em posição exata; em dados agrupados, usa a interpolação da fórmula abaixo, que é única. Se um item pedir quartil de um rol pequeno e o resultado ficar entre duas alternativas, é sinal de que você deve rever a leitura do enunciado — não a convenção.

$$\text{Dados agrupados em classes: } Md = l_{\text{inf}} + \frac{(n/2) - F_{\text{ant}}}{f_{\text{Md}}} \cdot h$$

l_{inf} = limite inferior da classe mediana; F_{ant} = frequência acumulada até a classe anterior; f_{Md} = frequência da classe mediana; h = amplitude

MEDIANA NA TABELA MESTRE

Passo 1. $n/2 = 50$. Procure na acumulada onde 50 é ultrapassado: $F = 20$ na segunda classe e $F = 60$ na terceira → a **classe mediana é 20** |— 30.

Passo 2. Identifique os elementos: $l_{\text{inf}} = 20$; $F_{\text{ant}} = 20$; $f_{\text{Md}} = 40$; $h = 10$.

Passo 3. $Md = 20 + [(50 - 20)/40] \times 10 = 20 + 0,75 \times 10 = 20 + 7,5 = \text{R\$ } 27,5 \text{ mil}$

Interpretação: metade dos contribuintes recolheu até R\$ 27,5 mil. Note que a média (28) é **maior** — primeiro sinal de assimetria positiva.

1.6.4 Moda

Valor (ou classe) de **maior frequência**. É a única medida de posição aplicável a variável **nominal**, e a única que pode não existir ou ser múltipla.

- **Amodal:** todas as frequências iguais — não há moda.
- **Bimodal / multimodal:** dois ou mais valores empatados na maior frequência.
- **Moda bruta**, em dados agrupados: simplesmente o ponto médio da classe modal (na tabela mestre, 25). É a aproximação grosseira.

$$\text{Moda de Czuber (a mais cobrada): } Mo = l_{\text{inf}} + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot h$$

$$\Delta_1 = f_{\text{modal}} - f_{\text{anterior}} \quad \Delta_2 = f_{\text{modal}} - f_{\text{posterior}}$$

MODA NA TABELA MESTRE

Passo 1. Classe modal = a de maior frequência = **20** |— **30** ($f = 40$).

Passo 2. $\Delta_1 = 40 - 15 = 25$ · $\Delta_2 = 40 - 25 = 15$.

Passo 3. $Mo = 20 + [25/(25 + 15)] \times 10 = 20 + 0,625 \times 10 = \text{R\$ } 26,25 \text{ mil}$

Lógica da fórmula: a moda é "puxada" para o lado da classe vizinha de maior frequência. Como a classe posterior (25) é mais cheia que a anterior (15), a moda fica **acima** do ponto médio 25.

A RELAÇÃO EMPÍRICA DE PEARSON — RESOLVE ITEM DE ASSIMETRIA SEM CONTA NENHUMA

FORMA DA DISTRIBUIÇÃO	ORDEM DAS TRÊS MEDIDAS	CAUDA MAIS LONGA
Simétrica (unimodal)	moda = mediana = média	nenhuma
Assimétrica positiva (à direita)	moda < mediana < média	à direita
Assimétrica negativa (à esquerda)	média < mediana < moda	à esquerda

Mnemônico: a **média foge para o lado da cauda** — porque é ela, e só ela, que sofre a atração dos valores extremos.

Na tabela mestre: $Mo = 26,25 < Md = 27,5 < \bar{x} = 28$ → **assimetria positiva**, exatamente o esperado para valores monetários.

Vale ainda a relação aproximada **média – moda $\approx$ 3 (média – mediana)**: aqui, 1,75 contra $3 \times 0,5 = 1,5$ — próximo, como a natureza empírica da regra permite.

1.7 Separatrizes: quartis, decis e percentis

Generalizam a mediana: são valores que dividem o rol ordenado em partes de tamanho igual.

- **Quartis** (Q_1, Q_2, Q_3) — dividem em **quatro** partes de 25% cada.

- **Decis** (D_1 a D_9) — em **dez** partes de 10%.
- **Percentis** (P_1 a P_{99}) — em **cem** partes de 1%.

$$Q_1 = D_{2,5} = P_{25} \cdot Q_2 = D_5 = P_{50} = \textbf{mediana} \cdot Q_3 = D_{7,5} = P_{75}$$

Equivalências de memorização obrigatória

Em classes:
$$Q_i = l_{\text{inf}} + \frac{(i \cdot n/4) - F_{\text{ant}}}{f} \cdot h$$

Mesma estrutura da mediana; troque $n/2$ pela fração desejada ($i \cdot n/4$ para quartis, $i \cdot n/10$ para decis, $i \cdot n/100$ para percentis)

QUARTIS E PERCENTIS NA TABELA MESTRE

Q_1 — posição $25\% \times 100 = 25$. A acumulada passa de 20 para 60 na terceira classe → classe 20 — 30.

$$Q_1 = 20 + [(25 - 20)/40] \times 10 = 20 + 1,25 = \textbf{21,25}$$

Q_3 — posição 75. A acumulada passa de 60 para 85 na quarta classe → classe 30 — 40.

$$Q_3 = 30 + [(75 - 60)/25] \times 10 = 30 + 6 = \textbf{36}$$

P_{10} — posição 10 → classe 10 — 20: $10 + [(10 - 5)/15] \times 10 = 10 + 3,33 = \textbf{13,33}$

P_{90} — posição 90 → classe 40 — 50: $40 + [(90 - 85)/15] \times 10 = 40 + 3,33 = \textbf{43,33}$

Uso fiscal direto: o P_{90} é a régua de seleção de malha fina — "auditar os 10% que mais recolhem" significa auditar quem está acima de R\$ 43,33 mil.

QUARTIL É POSIÇÃO; DIFERENÇA DE QUARTIS É DISPERSÃO

Tomados isoladamente, Q_1 e Q_3 localizam pontos da distribuição — são **posição**. A diferença $Q_3 - Q_1$ mede o espalhamento dos 50% centrais — é **dispersão**. Essa distinção foi objeto de questão inteira na SEFAZ/RJ 2025 e é a armadilha mais provável de aparecer em Alagoas.

1.8 Medidas de dispersão

Duas distribuições podem ter exatamente a mesma média e serem completamente diferentes. As medidas de dispersão respondem "quão espalhados estão os dados em torno do centro?".

MEDIDA	FÓRMULA	UNIDADE	CARACTERÍSTICA DECISIVA
Amplitude total	máx - mín	a dos dados	Usa só duas observações; extremamente sensível a outlier
Amplitude interquartílica (AIQ)	$Q_3 - Q_1$	a dos dados	Robusta ; mede os 50% centrais; base do boxplot
Desvio médio absoluto	$\Sigma x_i - \bar{x} / n$	a dos dados	Usa o módulo porque a soma simples dos desvios é zero
Variância populacional σ^2	$\Sigma (x_i - \mu)^2 / N$	ao quadrado	Divide por N
Variância amostral s^2	$\Sigma (x_i - \bar{x})^2 / (n - 1)$	ao quadrado	Divide por $n - 1$ (correção de Bessel), para ser estimador não viesado
Desvio padrão	$\sqrt{\text{variância}}$	a dos dados	Nunca negativo; é zero se e somente se todos os valores forem iguais
Coefficiente de variação	$CV = s / \bar{x} (\times 100)$	adimensional	Único que compara dispersões de escalas ou unidades diferentes

POR QUE A VARIÂNCIA AMOSTRAL DIVIDE POR $N - 1$

Ao usar $\bar{x}$ (calculado da própria amostra) no lugar de μ (desconhecido), a soma dos quadrados fica *sistematicamente menor* do que seria em torno da média verdadeira — porque a média amostral é, por definição, o ponto que minimiza essa soma. Dividir por $n - 1$ em vez de n corrige esse encolhimento e torna o estimador **não viesado**: $E(s^2) = \sigma^2$. O termo $n - 1$ é o número de **graus de liberdade** — perde-se um grau porque a média já foi estimada dos mesmos dados.

Atalho de cálculo: $\sigma^2 = E(X^2) - [E(X)]^2$

"média dos quadrados menos o quadrado da média" — resolve variância em duas linhas, sem tabela de desvios

VARIÂNCIA, DESVIO PADRÃO E CV NA TABELA MESTRE — PELOS DOIS CAMINHOS

Caminho 1 — pela definição. Com $\bar{x} = 28$, calcule $f_i(x_i - 28)^2$:

$5 \rightarrow (-23)^2 \times 5 = 2.645$ · $15 \rightarrow (-13)^2 \times 15 = 2.535$ · $25 \rightarrow (-3)^2 \times 40 = 360$ · $35 \rightarrow 7^2 \times 25 = 1.225$ · $45 \rightarrow 17^2 \times 15 = 4.335$
Soma = **11.100**. Variância populacional = $11.100/100 = 111$.

Caminho 2 — pelo atalho. $\sum f_i x_i^2 = 25(5) + 225(15) + 625(40) + 1.225(25) + 2.025(15) = 125 + 3.375 + 25.000 + 30.625 + 30.375 = 89.500$.

$E(X^2) = 89.500/100 = 895$. $\sigma^2 = 895 - 28^2 = 895 - 784 = 111$ ✓

Desvio padrão: $\sigma = \sqrt{111} \approx 10,54$ (mesma unidade dos dados: R\$ mil).

Versão amostral: $s^2 = 11.100/99 \approx 112,12 \rightarrow s \approx 10,59$. Repare que **a versão amostral é sempre maior**.

Coefficiente de variação: $CV = 10,54/28 = 0,376 \rightarrow 37,6\%$ — dispersão alta, coerente com dados monetários.

EFEITO DAS TRANSFORMAÇÕES LINEARES — DECORE ESTE QUADRO

SE $Y = \dots$	MÉDIA	DESVIO PADRÃO	VARIÂNCIA	AIQ	CV
$x + a$ (somar constante)	$\bar{x} + a$	não muda	não muda	não muda	muda
$b \cdot x$ (multiplicar)	$b \cdot \bar{x}$	$ b \cdot s$	$b^2 \cdot s^2$	$ b \cdot \text{AIQ}$	não muda

Leitura: somar constante desloca a distribuição inteira sem alterar o espalhamento; multiplicar reescala tudo. Duas consequências campeãs de item: **o dobro no desvio padrão é o quádruplo na variância**, e **o CV é invariante à multiplicação, mas não à soma** (a banca inverte isso com frequência).

CUIDADO COM "CV BAIXO INDICA DISPERSÃO BAIXA"

Não há limiar legal. A convenção didática mais difundida trata **CV < 15%** como dispersão baixa, entre 15% e 30% como média e **CV > 30%** como alta. O CEBRASPE, porém, costuma cobrar apenas a **comparação numérica** ("o CV é inferior a 7%, o que indica dispersão baixa" — TC/DF 2024, item 28, CERTO). **Confira a conta; não brigue com o adjetivo.**


1.9 Assimetria — a primeira medida de forma

A assimetria mede **o quanto a distribuição se afasta do espelhamento** em torno do centro. É o terceiro momento da distribuição, e o edital a cobra nominalmente.

COEFICIENTE	INTERPRETAÇÃO	RELAÇÃO ENTRE AS MEDIDAS	APARÊNCIA
= 0	Simétrica	média = mediana = moda	Espelhada em torno do centro
> 0	Assimétrica positiva (ou "à direita")	moda < mediana < média	Concentração à esquerda, cauda longa à direita


COEFICIENTE	INTERPRETAÇÃO	RELAÇÃO ENTRE AS MEDIDAS	APARÊNCIA
< 0	Assimétrica negativa (ou "à esquerda")	média < mediana < moda	Concentração à direita, cauda longa à esquerda

Assimétrica negativa cauda longa à esquerda



média < mediana < moda


Simétrica sem cauda dominante



Mo = Md = $\bar{x}$

as três coincidem

Assimétrica positiva cauda longa à direita



Mo $\bar{x}$

Md

moda < mediana < média

Leitura. Em cada painel, a **moda** está sob o pico, e a **média** é sempre a que mais se desloca na direção da cauda — a mediana fica no meio do caminho. É por isso que basta enxergar de que lado está a cauda para ordenar as três medidas, sem calcular nada. Repare que a distribuição da tabela mestre (figura da seção 1.4.1) é do tipo do **painel da direita**.

O NOME VEM DA CAUDA, NÃO DA CONCENTRAÇÃO

"Assimétrica à direita" significa que a **cauda** se estende para a direita — e portanto que a massa dos dados está à **esquerda**. É contraintuitivo e é exatamente por isso que a banca usa a formulação. Um item que diga "há maior concentração de valores à esquerda da mediana, logo a assimetria é negativa" está **ERRADO**: concentração à esquerda é assimetria **positiva**.

Os coeficientes

$$\text{1.º coeficiente de Pearson: } A_P = \frac{\bar{x} - Mo}{s} \quad \text{2.º coeficiente de Pearson: } A_P = \frac{3(\bar{x} - Md)}{s}$$

O segundo é preferível quando a moda é mal definida (distribuição amodal ou multimodal)

$$\text{Coeficiente quartílico de Bowley: } A_B = \frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{Q_3 - Q_1}$$

Varia sempre entre -1 e +1; é **robusto**, pois só usa quartis

A lógica de Bowley é transparente: compara a distância do Q_3 à mediana com a distância da mediana ao Q_1 . Se a metade superior é mais "esticada", o numerador é positivo — assimetria positiva.

ASSIMETRIA NA TABELA MESTRE — TRÊS COEFICIENTES, UMA CONCLUSÃO

Recapitulando: $\bar{x} = 28$ · $Md = 27,5$ · $Mo = 26,25$ · $\sigma = 10,54$ · $Q_1 = 21,25$ · $Q_3 = 36$.

1.º de Pearson: $(28 - 26,25)/10,54 = 1,75/10,54 = +0,166$

2.º de Pearson: $3(28 - 27,5)/10,54 = 1,5/10,54 = +0,142$

Bowley: $[(36 - 27,5) - (27,5 - 21,25)]/(36 - 21,25) = (8,5 - 6,25)/14,75 = 2,25/14,75 = +0,153$


Conclusão: os três apontam **assimetria positiva fraca**. Coeficientes de Pearson em módulo abaixo de 0,15 são usualmente lidos como assimetria fraca; entre 0,15 e 1, moderada; acima de 1, forte.

1.10 Curtose — a segunda medida de forma

A curtose mede o **grau de achatamento** da distribuição, comparado ao da curva normal. Tecnicamente é o quarto momento, e o que ela de fato captura é o **peso das caudas**: distribuições leptocúrticas têm mais valores extremos do que a normal.

NOME	COEFICIENTE MOMENTO B_2	EXCESSO ($B_2 - 3$)	ASPECTO	CAUDAS
Leptocúrtica	> 3	> 0	Pico alto e estreito	Pesadas — mais outliers
Mesocúrtica	$= 3$	$= 0$	Referência: a normal	Normais
Platicúrtica	< 3	< 0	Achatada, espalhada	Leves

Mnemônico: **lepto** — de *leptós*, "delgado": pico esguio e alto. **Plati** — de *platýs*, "plano": plataforma, achatada. **Meso** — "meio": a normal, no meio-termo. **Atenção ao referencial:** alguns enunciados dão o coeficiente β_2 centrado em 3; outros dão o *excesso de curtose*, centrado em 0. Leia com cuidado qual dos dois o item usa — a inversão do referencial é armadilha frequente.



Leitura. As três curvas têm a mesma área (probabilidade total 1). O que muda é a **concentração no pico** e, como consequência, o **peso das caudas** — e é o peso das caudas, não a altura do pico, o que a curtose de fato mede. Em auditoria isso importa: uma distribuição leptocúrtica de valores de nota fiscal significa **mais outliers do que o esperado**.

Coeficiente percentílico de curtose: $K = \frac{Q_3 - Q_1}{2 (P_{90} - P_{10})}$

Referência: **0,263** para a distribuição normal

A RELAÇÃO DO COEFICIENTE PERCENTÍLICO É INVERTIDA

Ao contrário do coeficiente de momento, no percentílico **quanto maior o valor, mais achatada** é a distribuição:

- $K = 0,263 \rightarrow$ **mesocúrtica**
- $K > 0,263 \rightarrow$ **platicúrtica** (achatada)
- $K < 0,263 \rightarrow$ **leptocúrtica** (afilada)

A razão é intuitiva: se as caudas são pesadas (leptocúrtica), $P_{90} - P_{10}$ cresce muito mais do que a AIQ, e o quociente cai. Quem decora "maior = mais afilada" — a regra do coeficiente de momento — erra o item.

CURTOSE NA TABELA MESTRE

Já calculados: $Q_1 = 21,25$ · $Q_3 = 36$ · $P_{10} = 13,33$ · $P_{90} = 43,33$.

Passo 1. $AIQ = 36 - 21,25 = 14,75$.

Passo 2. $P_{90} - P_{10} = 43,33 - 13,33 = 30$.

Passo 3. $K = 14,75 / (2 \times 30) = 14,75/60 = \mathbf{0,246}$

Conclusão: $0,246 < 0,263 \rightarrow$ distribuição **leptocúrtica**, ligeiramente mais afilada que a normal — coerente com uma distribuição de valores monetários, que costuma concentrar massa no centro e produzir alguns extremos altos.

RESUMO DO EXEMPLO MESTRE — TODA A DESCRITIVA EM UMA LINHA

MÉDIA	MEDIANA	MODA	Q_1	Q_3	AIQ	Σ	CV	ASSIM.	CURTOSE
28,00	27,50	26,25	21,25	36,00	14,75	10,54	37,6%	+0,15	0,246

Leitura integrada: distribuição de valores monetários com dispersão alta (CV 37,6%), levemente assimétrica à direita (moda < mediana < média) e um pouco mais afilada que a normal. Se você consegue produzir essa frase a partir de uma tabela de frequências, os quatro itens de descritiva da prova estão resolvidos.


1.11 Boxplot, outliers e o resumo dos cinco números

O boxplot (diagrama de caixa) é a ferramenta emblemática da análise exploratória. Constrói-se sobre o **resumo dos cinco números**: mínimo, Q_1 , **mediana**, Q_3 e máximo.

- A **caixa** vai de Q_1 a Q_3 — contém, portanto, **50% das observações centrais**, e seu comprimento é a AIQ.
- O **traço interno** é a **mediana** — nunca a média. Item que diga "a linha central do boxplot representa a média" é **ERRADO**.
- Os **bigodes** (whiskers) estendem-se até a observação mais extrema que ainda esteja dentro dos limites; além deles, os pontos são plotados individualmente como **outliers**.

Anatomia do boxplot — a distribuição da tabela mestre

ICMS recolhido (R\$ mil)



A mediana está mais próxima de Q_1 e o bigode direito é mais longo → assimetria positiva.

Leitura. O traço grosso dentro da caixa é a **mediana**, jamais a média — item que diga o contrário é errado. Como o máximo observado (50) fica **aquém** do limite de 58,1, este conjunto **não tem outliers**. E a assimetria se lê pela geometria: caixa deslocada para a esquerda e bigode direito mais longo é a assinatura da assimetria positiva já confirmada pelos coeficientes.

$$\text{Limite inferior} = Q_1 - 1,5 \times AIQ \quad \cdot \quad \text{Limite superior} = Q_3 + 1,5 \times AIQ$$

Observações fora desses limites são **outliers**; usando $3,0 \times AIQ$, são outliers *extremos*

LIMITES DE OUTLIER NA TABELA MESTRE

$AIQ = 14,75 \rightarrow 1,5 \times AIQ = 22,125$.

Limite inferior: $21,25 - 22,125 = -0,875$ — como o ICMS não é negativo, **não há outliers inferiores possíveis**.

Limite superior: $36 + 22,125 = 58,125$ — acima disso, o contribuinte seria atípico. Como o máximo da tabela é 50, **não há outliers** neste conjunto.

Aplicação fiscal: é exatamente esse cálculo que sustenta a seleção automática de contribuintes para malha fina por critério de dispersão — foi o objeto do item 10 do ANEEL 2025.

Lendo a forma no boxplot

- **Mediana centrada** na caixa e bigodes de comprimento parecido $\rightarrow$ distribuição aproximadamente **simétrica**.
- **Mediana mais próxima de Q_1** e bigode superior mais longo $\rightarrow$ **assimetria positiva**.
- **Mediana mais próxima de Q_3** e bigode inferior mais longo $\rightarrow$ **assimetria negativa**.
- Boxplots lado a lado comparam **níveis** (posição das caixas) e **variabilidades** (comprimento das caixas) entre grupos — é o uso mais comum em auditoria.

O gráfico de ramo-e-folhas

Alternativa exploratória ao histograma que **preserva os valores originais**. Cada linha traz um "ramo" (as dezenas, por exemplo) e, à direita, as "folhas" (as unidades). Vantagem: mostra a forma da distribuição e permite recuperar cada dado — logo, permite calcular mediana e quartis diretamente do gráfico, o que o histograma não permite.

1.12 Teste rápido — Tópico 1

Oito itens no formato da prova, escritos sobre os pontos que a banca mais explora. Julgue CERTO ou ERRADO antes de ver o gabarito.

#	ITEM	C/E	POR QUÊ
1	O coeficiente de variação é expresso na mesma unidade dos dados.	E	É adimensional — é essa a razão de existir
2	Somando-se R\$ 100 a todos os valores, o desvio padrão aumenta em R\$ 100.	E	Somar constante não altera dispersão alguma
3	Se todos os valores forem multiplicados por 3, a variância será multiplicada por 9.	C	$\text{Var}(bx) = b^2\text{Var}(x)$
4	Em distribuição com assimetria positiva, a média é inferior à mediana.	E	Positiva: $\text{moda} < \text{mediana} < \text{média}$
5	A amplitude interquartilica é medida de posição, por ser obtida a partir dos quartis.	E	Quartil é posição; a diferença é dispersão
6	Distribuição com coeficiente de curtose por momento igual a 4,1 é platicúrtica.	E	Maior que 3 é leptocúrtica
7	Distribuição com coeficiente percentílico de curtose igual a 0,31 é platicúrtica.	C	No percentílico a relação é invertida : acima de 0,263 é achatada
8	Em um histograma com classes de amplitudes diferentes, a altura da barra representa a frequência da classe.	E	Nesse caso é a área que representa a frequência

Diagnóstico. Menos de 6 acertos: releia as seções 1.8 a 1.10, que concentram o que a banca transforma em item. Os pares 6/7 são o teste decisivo — quem acerta os dois domina a única armadilha realmente traiçoeira de curtose.

1.13 Questões reais comentadas — Tópico 1

CEBRASPE · TC/DF 2024 · AUDITOR DE CONTROLE EXTERNO · ITENS 28 A 31

Gráfico da taxa de fecundidade no Brasil (10 observações, de 2,32 em 2000 a 1,57 em 2023). Considere que a média da sequência seja $\mu = 1,8$ e que a variância seja $\sigma^2 = 0,014$.

28 — O valor do coeficiente de variação (ou coeficiente de variação de Pearson) é inferior a 7%, o que indica uma dispersão baixa dos dados dessa sequência.

CERTO. *Justificativa oficial:* "O coeficiente de variação é dado por $CV = \sigma/\mu \times 100 = 0,11/1,8 \approx 6,2 < 7\%$."

Detalhe do cálculo: a banca usa $\sigma = \sqrt{0,014} \approx 0,1183$, arredonda para 0,11 e obtém $0,11/1,8 = 6,1\%$. Ainda que se use 0,1183 sem arredondar, o resultado é 6,6% — abaixo de 7% de qualquer modo. **Quando o item pede uma comparação com limiar, teste a folga:** se o resultado só muda com arredondamento agressivo, o gabarito é robusto.

CEBRASPE · TC/DF 2024 · ITEM 30

O desvio padrão é inferior a 0,11, o que indica uma variação baixa dos dados em relação à média.

ERRADO. *Justificativa oficial:* "O desvio padrão é a raiz quadrada da variância. Assim, $\sigma = \sqrt{0,014} > 0,11$."

Leitura de prova: os itens 28 e 30 usam o mesmo número e chegam a gabaritos opostos. Isso é deliberado. No item 28, 0,11 é uma aproximação suficiente para a comparação com 7%; no item 30, a comparação é **com o próprio 0,11**, e aí o arredondamento deixa de ser inocente: $\sqrt{0,014} = 0,1183$, que é maior que 0,11. Quem decorou " $\sigma = 0,11$ " do item anterior, sem calcular a raiz, erra.

Lição transferível: a banca reutiliza o mesmo conjunto de dados em itens consecutivos com exigências de precisão diferentes.

CEBRASPE · TC/DF 2024 · ITENS 29 E 31

29 — A moda dessa sequência de dados é 10% superior à sua média.

31 — A mediana dessa sequência de dados é inferior à sua média.

29: ERRADO — a moda é 1,74 (valor que se repete), portanto inferior à média 1,8. O item afirma o contrário e ainda quantifica errado.

31: CERTO — *justificativa oficial:* ordenando os 10 dados ($2 \cdot 1,95 \cdot 1,9 \cdot 1,8 \cdot 1,78 \cdot 1,77 \cdot 1,75 \cdot 1,74 \cdot 1,74 \cdot 1,57$), como n é par a mediana é a média dos dois centrais: $(1,78 + 1,77)/2 = 1,775 < 1,8$.

Repare no padrão: moda 1,74 < mediana 1,775 < média 1,8 — a assinatura exata de uma distribuição com **assimetria positiva**, tal como a tabela da seção 1.6.4. Quem reconhece o padrão responde os dois itens sem ordenar nada.

CEBRASPE · SEEC/DF 2019 · AUDITOR-FISCAL DA RECEITA DO DF · ITEM 74

A partir de uma amostra aleatória simples de tamanho n , sabe-se que a média aritmética de uma variável X foi igual a 3. Os valores possíveis de X são -1 e $+4$.

Nessa amostra, a quantidade de observações iguais a $+4$ foi igual a $0,8n$.

CERTO. *Justificativa oficial (resumida):* com dois estados possíveis, a média pode ser escrita como $4f + (-1)(1 - f)$, em que f é a frequência relativa de observações iguais a $+4$. Igualando a 3: $5f - 1 = 3 \rightarrow f = 0,8$.

Molde a memorizar: variável de dois valores vira sempre uma equação de primeiro grau na frequência relativa. É o formato mais econômico de questão de média que a banca usa, e reaparece em probabilidade como variável de Bernoulli.

CEBRASPE · SEEC/DF 2019 · ITENS 75, 76 E 77

75 — O desvio padrão amostral de X foi igual ou superior a 2.

76 — A mediana amostral de X foi igual a 2,5.

77 — A distribuição da variável X é simétrica em torno da sua média amostral.

75: CERTO — use o atalho: $E(X^2) = 16(0,8) + 1(0,2) = 12,8 + 0,2 = 13$ e $[E(X)]^2 = 9$. Logo a variância populacional é $13 - 9 = 4$ e o desvio padrão, exatamente 2. Com a correção de Bessel (divisão por $n - 1$), o valor fica **superior** a 2 — daí a formulação "igual ou superior", que cobre os dois casos.

76: ERRADO — 80% das observações valem +4; logo, ordenando o rol, o valor central é 4. Quem calcula $(-1 + 4)/2 = 1,5$, ou toma "o ponto médio dos valores possíveis", cai na armadilha: **mediana é posição no rol, não média dos extremos**.

77: ERRADO — *justificativa oficial*: a variável é assimétrica, pois o valor da média amostral sugere frequência muito menor de observações iguais a -1. Formalmente: média 3, mediana 4, moda 4 → média < mediana = moda → **assimetria negativa**.

CEBRASPE · SEFAZ/RJ 2025 · AUDITOR FISCAL · QUESTÃO 55

Um auditor observa que $Q_1 = R\$ 1.000$ e $Q_3 = R\$ 9.000$. A diferença $Q_3 - Q_1$, chamada de amplitude interquartilica, representa uma medida de

A dispersão. B curtose. C posição. D assimetria (positiva). E assimetria (negativa).

Gabarito: A. Os quartis, isoladamente, são medidas de *posição* — e é isso que a alternativa C explora. A **diferença** entre dois deles mede espalhamento, logo é **dispersão**.

Convertido para certo/errado, o mesmo conteúdo viraria: "a amplitude interquartilica é uma medida de posição, pois é obtida a partir dos quartis" — ERRADO, com a estrutura afirmação + justificativa da seção 0.4.

CEBRASPE · SEFAZ/RJ 2025 · QUESTÃO 56

Distribuição de frequência absoluta da variável quantitativa discreta Y : valor 20 com frequência 13; valor 40 com frequência 13; total 26.

Assinale a opção que apresenta corretamente a variância **amostral** de Y .

A 10 B 20 C 104 D 400 E 676

Gabarito: C. Média = $(20 \times 13 + 40 \times 13) / 26 = 780 / 26 = 30$. Cada desvio vale ± 10 , logo $\Sigma(y_i - \bar{y})^2 = 26 \times 100 = 2.600$. Variância **amostral**: $2.600 / (26 - 1) = 104$.

As alternativas mapeiam os erros típicos: $2.600 / 26 = 100$ é a variância *populacional*, e sua raiz, 10, é a alternativa A; 20 (alternativa B) é um dos valores observados; 400 e 676 (D e E) são 20^2 e 26^2 . O enunciado pediu **amostral** — o denominador é $n - 1$.

Atalho: quando a variável assume só dois valores com frequências iguais, o desvio de cada observação é sempre metade da distância entre os valores — aqui, 10 — e a variância populacional é o quadrado disso, 100, sem qualquer soma.

Trecho de relatório: "A despesa média observada foi de R\$ 2.150, com mediana de R\$ 2.000 e moda de R\$ 1.800. O valor mínimo registrado foi de R\$ 950, enquanto o máximo atingiu R\$ 4.600. O primeiro quartil foi de R\$ 1.600 e o terceiro, de R\$ 2.700 (...). O percentil 90 situou-se em R\$ 3.800. O desvio padrão amostral foi de R\$ 620, com coeficiente de variação de aproximadamente 28,8%. Observou-se assimetria positiva, com coeficiente de assimetria igual a 0,9, e curtose igual a 3,4."

A quantidade de medidas de **dispersão** explicitamente mencionadas é igual a

A 1 B 2 C 3 D 4 E 5

Gabarito oficial: C (três). Duas medidas são incontroversas — **desvio padrão** (620) e **coeficiente de variação** (28,8%). A terceira, na leitura da banca, vem do par mínimo/máximo, que expressa a **amplitude total** ($4.600 - 950 = \text{R\$ } 3.650$).

Item polêmico, e vale saber por quê: "explicitamente mencionadas" comportaria a leitura estrita de apenas duas medidas, já que a amplitude não é nomeada. Registre-o pelo que ele de fato treina — a **taxonomia**:

- **Posição:** média, mediana, moda, Q_1 , Q_3 , P_{90} , mínimo e máximo isolados
- **Dispersão:** desvio padrão, CV, amplitude (do par mín-máx)
- **Forma:** assimetria (0,9) e curtose (3,4)

Se você separa as três famílias com segurança, resolve o item independentemente de onde a banca traça a fronteira do "explicitamente".

Bônus: curtose $3,4 > 3$ indica distribuição **leptocúrtica**, e moda $<$ mediana $<$ média confirma a assimetria positiva declarada.

CEBRASPE · BCB 2024 · ITENS 26, 29 E 30

Variável aleatória X com suporte $\{-2, -1, 0, +1, +2\}$ e função de probabilidade $P(X = x)$ igual a $5c$, c , $2c$, $3c$ e $4c$, respectivamente, com c constante real positiva.

26 — A moda de X é igual a zero.

29 — A média de X é igual a zero.

30 — A mediana de X é igual ou superior a 1.

Passo zero, comum aos três: as probabilidades somam 1, então $5c + c + 2c + 3c + 4c = 15c = 1 \rightarrow c = 1/15$.

26: ERRADO — a maior probabilidade é $5c$, em $x = -2$. Moda é o valor de *maior probabilidade*, não o valor central do suporte.

29: CERTO — $E(X) = [(-2)(5) + (-1)(1) + (0)(2) + (1)(3) + (2)(4)]/15 = (-10 - 1 + 0 + 3 + 8)/15 = 0/15 = 0$.

30: ERRADO — acumule: $5/15$ em $x = -2$; $6/15$ em -1 ; $8/15$ em 0 . A acumulada cruza 50% em $x = 0$, que é a mediana — inferior a 1.

Este é o trio perfeito de descritiva: um item de moda, um de média e um de mediana sobre a mesma tabela. Note que aqui a distribuição tem média 0, mediana 0 e moda -2 — **moda $<$ mediana = média**, padrão de assimetria positiva.

CEBRASPE · BCB 2024 · ITENS 31 E 35

V e W são variáveis contínuas mutuamente independentes.

31 — Considerando-se que as médias de V e W sejam iguais a 1 e que o coeficiente de variação de V seja igual ao **dobro** do de W , é correto concluir que a variância de V deve ser igual ao dobro da variância de W .

35 — Se o desvio padrão de V for 3 e o de W for 4, então o desvio padrão da diferença $V - W$ será igual a 5.

31: ERRADO. Com ambas as médias iguais a 1, o CV coincide numericamente com o desvio padrão ($CV = \sigma/1$). Se $\sigma_V = 2\sigma_W$, então $\text{Var}(V) = (2\sigma_W)^2 = 4 \cdot \text{Var}(W)$ — **quatro** vezes, não duas. É a aplicação direta do quadro de transformações lineares da seção 1.8: o **dobro** no desvio padrão é o **quádruplo** na variância.

35: CERTO. Independentes $\Rightarrow \text{Cov} = 0 \Rightarrow \text{Var}(V - W) = \text{Var}(V) + \text{Var}(W) = 9 + 16 = 25 \Rightarrow$ desvio padrão = 5. Observe que, na **diferença**, as variâncias **somam** — quem subtrai ($\sqrt{16 - 9} = \sqrt{7}$) erra. A intuição: subtrair duas fontes independentes de incerteza acumula incerteza, não a cancela.

TÓPICO 2 · PROBABILIDADE — DEFINIÇÕES, AXIOMAS, CONDICIONAL E INDEPENDÊNCIA

Corresponde aos itens 3, 3.1 e 3.2 do programa: "Probabilidade. Definições básicas e axiomas. Probabilidade condicional e independência."

2.1 Vocabulário mínimo e álgebra de eventos

CONCEITO	DEFINIÇÃO	EXEMPLO FISCAL
Experimento aleatório	Procedimento cujo resultado não é previsível com certeza, mas cujo conjunto de resultados possíveis é conhecido e que pode ser repetido nas mesmas condições	Sortear uma declaração para auditoria
Espaço amostral Ω	Conjunto de todos os resultados possíveis	Todas as declarações do exercício
Ponto amostral	Cada elemento de Ω	Uma declaração específica
Evento	Qualquer subconjunto de Ω	"A declaração tem inconsistência"
Evento certo	Ω — ocorre sempre; $P = 1$	—
Evento impossível	$\emptyset$ — nunca ocorre; $P = 0$	"Empresa do Simples e do lucro real ao mesmo tempo"
Eventos mutuamente exclusivos	$A \cap B = \emptyset$ — não podem ocorrer juntos	Regimes tributários distintos
Eventos exaustivos	A união deles é Ω — pelo menos um ocorre	Todos os regimes possíveis
Partição de Ω	Eventos mutuamente exclusivos e exaustivos	A classificação completa por regime — base da probabilidade total
Evento complementar A^c	Tudo o que está em Ω e não em A	"A declaração não tem inconsistência"


Operações e as leis de De Morgan

- **União** ($A \cup B$) — ocorre **pelo menos um** dos dois. Na linguagem do enunciado: "**ou**".
- **Interseção** ($A \cap B$) — ocorrem **ambos**. Na linguagem do enunciado: "**e**", "simultaneamente", "ao mesmo tempo".
- **Diferença** ($A - B = A \cap B^c$) — ocorre A mas não B .


$$(A \cup B)^c = A^c \cap B^c \quad \cdot \quad (A \cap B)^c = A^c \cup B^c$$

Leis de De Morgan — "não (A ou B)" = "nem A nem B"; "não (A e B)" = "não A ou não B"


União $A \cup B$
ocorre pelo menos um




Interseção $A \cap B$
ocorrem ambos



Complementar A^c
tudo que não é A



Mutuamente exclusivos
 $A \cap B = \emptyset$



Leitura. O quarto painel é o que mais rende item: círculos que **não se tocam** representam eventos que não podem ocorrer juntos — e é exatamente por isso que eles são **dependentes**, não independentes. Independência não tem representação geométrica no diagrama de Venn: é uma relação entre *áreas* (a área da interseção sendo o produto das áreas), e não entre posições. Guarde essa frase: **exclusividade se vê no desenho; independência, só na conta.**

A primeira lei é a que mais aparece: "**nenhum dos dois ocorreu**" é o complementar da união. É ela que justifica, em eventos independentes, escrever $P(A^c \cap B^c) = [1 - P(A)][1 - P(B)]$ — fórmula que resolveu a questão 58 da SEFAZ/RJ 2025.

2.2 As definições de probabilidade (item 3.1 — "definições básicas")

O edital fala em "definições básicas" no plural, e há de fato quatro concepções distintas — cada uma já foi objeto de item conceitual.

DEFINIÇÃO	ENUNCIADO	REQUISITO	LIMITAÇÃO
Clássica (Laplace)	$P(A)$ = casos favoráveis / casos possíveis	Todos os resultados equiprováveis e em número finito	Inútil quando os resultados não são igualmente prováveis
Frequentista (empírica)	Limite da frequência relativa quando o número de repetições tende ao infinito	Experimento repetível	Nunca se alcança o limite na prática
Subjetiva (bayesiana)	Grau de crença racional do observador	Coerência interna	Não é verificável objetivamente
Axiomática (Kolmogorov)	Qualquer função que satisfaça os três axiomas	—	Não diz <i>como</i> atribuir os valores

A definição **frequentista** foi cobrada literalmente no item 16 do ANA 2024: "repetindo-se muitas vezes o experimento (...) a frequência relativa converge para 20% do total" — CERTO. É a lei dos grandes números em linguagem de enunciado.

2.3 Os axiomas de Kolmogorov e o que decorre deles

OS TRÊS AXIOMAS — O EDITAL OS CITA NOMINALMENTE

1. **Não negatividade:** $P(A) \geq 0$, para todo evento A .
2. **Normalização:** $P(\Omega) = 1$.
3. **Aditividade:** se $A_1, A_2, \dots$ são **mutuamente exclusivos** dois a dois, então $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$

Tudo o mais é teorema, não axioma — e essa distinção já foi cobrada. Os principais decorrentes:

TEOREMA	ENUNCIADO	DE ONDE VEM
Evento impossível	$P(\emptyset) = 0$	Axiomas 2 e 3

TEOREMA	ENUNCIADO	DE ONDE VEM
Complementar	$P(A^c) = 1 - P(A)$	A e A^c são exclusivos e exaustivos
Limitação	$0 \leq P(A) \leq 1$	Axiomas 1 e 2
Monotonicidade	Se $A \subset B$, então $P(A) \leq P(B)$	Axiomas 1 e 3
Regra da adição	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	Evita contar duas vezes a interseção

Cuidado com a recíproca de $P(\emptyset) = 0$: probabilidade zero **não implica** evento impossível quando a variável é contínua. $P(T = 2 \text{ anos}) = 0$ e, no entanto, algum condutor pode ter exatamente 2 anos de habilitação.

A CONFUSÃO Nº 1 DE TODA PROVA: EXCLUSIVO ≠ INDEPENDENTE

São conceitos **opostos**, não sinônimos. É o erro mais caro da disciplina.

	MUTUAMENTE EXCLUSIVOS	INDEPENDENTES
Definição	$P(A \cap B) = 0$	$P(A \cap B) = P(A)P(B)$
Saber que A ocorreu...	... informa que B não ocorreu	... não informa nada sobre B
Trata de	Estrutura dos conjuntos	Relação entre as probabilidades

Consequência lógica que vale item: se $P(A) > 0$ e $P(B) > 0$, eventos mutuamente exclusivos são **necessariamente dependentes** — porque $P(A|B) = 0 \neq P(A)$.

2.4 Probabilidade condicional

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \text{ com } P(B) > 0$$

Lê-se "probabilidade de A **dado que** B ocorreu"

A intuição correta é a redução do espaço amostral. Ao saber que B ocorreu, o universo deixa de ser Ω e passa a ser B . Dentro desse novo universo, o que ainda interessa de A é a parte que está em B — daí o numerador ser a interseção e o denominador ser B . É por isso que o denominador não pode ser zero: não se condiciona em algo que não ocorre.

Regra do produto: $P(A \cap B) = P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$

É a mesma fórmula isolada de outra forma — e é a que resolve questão de árvore

A TROCA QUE A BANCA ADORA: MARGINAL NO LUGAR DA CONDICIONAL

Item 17 da SUSEP 2025: dados $P(A) = 0,2$ e $P(A|D) = 0,4$, o item afirmava que $P(A \cap D) = \mathbf{0,2} \times P(D)$. ERRADO: a regra do produto exige a **condicional**, isto é, $0,4 \times P(D)$. Usar a marginal só seria correto se A e D fossem independentes — e o próprio enunciado nega isso, já que $0,4 \neq 0,2$.

A TABELA DE DUPLA ENTRADA — O FORMATO MAIS EFICIENTE DE TREINAR CONDICIONAL

Toda probabilidade condicional pode ser lida diretamente de uma tabela de contingência, sem fórmula. Auditoria de 200 contribuintes, cruzando **regime tributário** com **resultado da fiscalização**:

	AUTUADO (D)	NÃO AUTUADO	TOTAL
Simples (S)	24	96	120
Lucro real	36	44	80
Total	60	140	200

Marginais (última linha e última coluna, sobre o total geral): $P(S) = 120/200 = 0,60$; $P(D) = 60/200 = 0,30$.

Conjunta (uma célula interna, sobre o total geral): $P(S \cap D) = 24/200 = 0,12$.

Condicional (uma célula sobre o total da sua linha ou coluna) — é aqui que está a redução do espaço amostral:

$P(D|S) = 24/120 = 0,20$ — dentro do Simples, 20% são autuados;

$P(S|D) = 24/60 = 0,40$ — entre os autuados, 40% são do Simples.

Repare que as duas condicionais são diferentes (0,20 e 0,40), embora partam da mesma célula. Trocar uma pela outra é o erro mais comum de toda a disciplina — e é precisamente o que Bayes serve para converter.

Teste de independência. Se fossem independentes, teríamos $P(S \cap D) = P(S) \cdot P(D) = 0,60 \times 0,30 = 0,18$. Mas o valor observado é $0,12 \neq 0,18 \rightarrow$ **são dependentes**. Equivalente: $P(D|S) = 0,20 \neq 0,30 = P(D)$ — *ser do Simples reduz a chance de autuação*.

União, para fechar: $P(S \cup D) = 0,60 + 0,30 - 0,12 = 0,78$. Conferindo pela contagem: $120 + 60 - 24 = 156$, e $156/200 = 0,78 \checkmark$ — a subtração da interseção é o que evita contar duas vezes os 24 que estão nas duas categorias.

A REGRA DE LEITURA DE QUALQUER TABELA DE CONTINGÊNCIA

O denominador denuncia o tipo de probabilidade. Dividiu pelo **total geral** $\rightarrow$ conjunta ou marginal. Dividiu pelo **total de uma linha ou coluna** $\rightarrow$ condicional. Se você souber apenas isso, resolve qualquer item construído sobre tabela de dupla entrada — e o CEBRASPE usa esse formato com frequência porque ele permite testar quatro conceitos com um único quadro.

2.5 Independência

Três definições equivalentes — provar uma prova as demais:

$$P(A \cap B) = P(A)P(B) \iff P(A|B) = P(A) \iff P(B|A) = P(B)$$

Condicionar em evento independente **não muda** a probabilidade — foi exatamente o item 34 do BCB 2024

Propriedade da herança: se A e B são independentes, então também o são os pares (A^c, B) , (A, B^c) e (A^c, B^c) . Daí:

$$P(A^c \cap B^c) = [1 - P(A)] \cdot [1 - P(B)]$$

"Nenhum dos dois ocorre", sob independência

INDEPENDÊNCIA DOIS A DOIS $\neq$ INDEPENDÊNCIA MÚTUA

Para que três eventos sejam **mutuamente independentes** não basta que cada par seja independente: exige-se **também** que $P(A \cap B \cap C) = P(A)P(B)P(C)$. O CEBRASPE emprega a expressão "mutuamente independentes" com precisão técnica — quando ela aparece, verifique se o enunciado de fato garante a condição conjunta, e não apenas as duas a duas.

2.6 Probabilidade total e teorema de Bayes

Sejam $B_1, B_2, \dots, B_k$ uma **partição** de Ω (exclusivos e exaustivos), todos com probabilidade positiva. Então:

$$\text{Probabilidade total: } P(A) = \sum P(A | B_i) \cdot P(B_i)$$

"Some todos os caminhos que levam a A, cada um pesado pela probabilidade de se tomar aquele caminho"

$$\text{Bayes: } P(B_j | A) = \frac{P(A | B_j) \cdot P(B_j)}{\sum P(A | B_i) \cdot P(B_i)}$$

"De todos os caminhos que levaram a A, que fração passou por B_j ?" — o denominador é a própria probabilidade total

COMO RECONHECER BAYES NO ENUNCIADO

Bayes aparece sempre que o enunciado **inverte o sentido do raciocínio**: fornece as probabilidades "da causa para o efeito" e pergunta a do efeito para a causa. As marcas linguísticas são "sabendo que o resultado foi X, qual a probabilidade de que...", "dado que já ocorreu..." e "selecionado um item defeituoso, qual a chance de ter vindo da linha B?".

Método infalível: monte a árvore, calcule a probabilidade de **cada caminho completo** (multiplicando ao longo dos ramos), some os caminhos que levam ao evento observado — esse é o denominador — e ponha no numerador apenas o caminho perguntado.

BAYES APLICADO À MALHA FINA — O EFEITO DA TAXA-BASE

Um sistema de cruzamento de dados classifica declarações. Sabe-se que **5%** das declarações contêm inconsistência real (I). O sistema **acusa** (A) 90% das declarações inconsistentes, mas também acusa 8% das declarações corretas (falso positivo). **Uma declaração foi acusada. Qual a probabilidade de ela ser realmente inconsistente?**

Passo 1 — os dois caminhos que levam à acusação:

· inconsistente e acusada: $P(I) \times P(A|I) = 0,05 \times 0,90 = \mathbf{0,045}$

· correta e acusada: $P(I^c) \times P(A|I^c) = 0,95 \times 0,08 = \mathbf{0,076}$

Passo 2 — probabilidade total: $P(A) = 0,045 + 0,076 = \mathbf{0,121}$ (12,1% das declarações são acusadas).

Passo 3 — Bayes: $P(I|A) = 0,045 / 0,121 \approx \mathbf{37,2\%}$

A lição contraintuitiva: um sistema que detecta 90% das fraudes produz, ainda assim, uma acusação que está **errada em 63% das vezes**. A razão é a **taxa-base**: como as declarações corretas são 19 vezes mais numerosas, mesmo uma taxa pequena de falso positivo gera muitos falsos alarmes. Esse raciocínio é o coração de qualquer item de Bayes em concurso fiscal.

A árvore da malha fina — dois caminhos levam à acusação



Leitura. Multiplique **ao longo** de cada caminho ($0,05 \times 0,90 = 0,045$) e some **entre** os caminhos que levam ao evento observado ($0,045 + 0,076 = 0,121$). Bayes é apenas a razão entre um caminho e a soma — nada além disso. E a figura torna visível o efeito da taxa-base: o ramo inferior é tão mais largo que, mesmo com apenas 8% de falso positivo, ele **contribui com mais acusações** (0,076) do que o ramo das declarações realmente inconsistentes (0,045).

2.7 Variáveis aleatórias — o mínimo que o programa exige

O edital de Alagoas não lista distribuições nominadas, mas os itens de "definições básicas" trabalham com variáveis aleatórias genéricas — como fez o BCB 2024. O necessário é o quadro abaixo.

	DISCRETA	CONTÍNUA
Suporte	Finito ou enumerável (valores isolados)	Intervalo da reta
Descrita por	Função de probabilidade , $P(X = x)$	Função densidade de probabilidade, $f(x)$
$P(X = a)$	Pode ser positiva	Sempre zero
Consequência	$\leq$ e $<$ produzem valores diferentes	$P(X \leq a) = P(X < a)$
Normalização	$\Sigma P(X = x) = 1$	Área total sob $f = 1$
Probabilidade de intervalo	Soma das probabilidades pontuais	Área sob a densidade

O item 18 da SUSEP 2025 e o item 28 do BCB 2024 exploram exatamente esta tabela: o primeiro atribui função de probabilidade pontual a variável contínua (ERRADO); o segundo chama de contínua uma variável de suporte $\{-2, -1, 0, 1, 2\}$ (ERRADO).

Esperança e variância

$$E(X) = \Sigma x \cdot P(X = x) \quad \cdot \quad \text{Var}(X) = E(X^2) - [E(X)]^2$$

$$E(aX + b) = a E(X) + b \quad \cdot \quad \text{Var}(aX + b) = a^2 \text{Var}(X)$$
$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y) \pm 2 \text{Cov}(X, Y)$$

Independentes $\Rightarrow \text{Cov} = 0 \Rightarrow$ as variâncias **somam**, tanto na soma quanto na diferença

Covariância e correlação

$$\text{Cov}(X,Y) = E(XY) - E(X)E(Y) \quad \cdot \quad \rho = \frac{\text{Cov}(X,Y)}{\sigma_X \cdot \sigma_Y}, \quad -1 \leq \rho \leq 1$$

INDEPENDÊNCIA IMPLICA CORRELAÇÃO ZERO — A RECÍPROCA É FALSA

Se X e Y são independentes, então $\text{Cov} = 0$ e $\rho = 0$. Mas $\rho = 0$ significa apenas ausência de relação **linear**: pode haver dependência perfeitamente determinística de forma não linear (por exemplo, $Y = X^2$ com X simétrico em torno de zero) e ainda assim correlação nula. Item que afirme "correlação zero implica independência" é **ERRADO**.

COMO A VARIÂNCIA DA SOMA RESOLVE UM ITEM DE CORRELAÇÃO — SEFAZ/RN 2025, Q. 51

Dadas $\text{Var}(A) = 1$, $\text{Var}(B) = 4$, $\text{Var}(C) = 9$, $\text{Var}(A + B + C) = 13$, e correlações $\rho_{AB} = \rho_{AC} = 0,5$, qual é ρ_{BC} ?

Passo 1. $\text{Var}(\text{soma}) = \Sigma \text{Var} + 2[\text{Cov}(A,B) + \text{Cov}(A,C) + \text{Cov}(B,C)] \rightarrow 13 = 14 + 2[\text{Cov}_{AB} + \text{Cov}_{AC} + \text{Cov}_{BC}]$.

Passo 2. $\text{Cov} = \rho \cdot \sigma_X \cdot \sigma_Y$. Desvios padrão: 1, 2 e 3. Logo $\text{Cov}_{AB} = 0,5(1)(2) = 1$ e $\text{Cov}_{AC} = 0,5(1)(3) = 1,5$.

Passo 3. $13 = 14 + 2[1 + 1,5 + \text{Cov}_{BC}] \rightarrow -1 = 2[2,5 + \text{Cov}_{BC}] \rightarrow \text{Cov}_{BC} = -3$.

Passo 4. $\rho_{BC} = -3/(2 \times 3) = -0,5$ (gabarito oficial: E).

O sinal de alerta: Var da soma (13) **menor** que a soma das variâncias (14) só é possível se houver covariância **negativa** em algum par. Perceber isso já elimina três alternativas.

2.8 Teste rápido — Tópico 2

Oito itens no formato da prova. Julgue antes de olhar o gabarito.

#	ITEM	C/E	POR QUÊ
1	Se A e B são mutuamente exclusivos e ambos têm probabilidade positiva, então são independentes.	E	São necessariamente dependentes
2	A regra $P(A \cup B) = P(A) + P(B)$ é um dos axiomas de Kolmogorov.	E	O axioma exige exclusividade; a regra geral subtrai a interseção — e é teorema , não axioma
3	Se A e B são independentes, $P(A B) = P(A)$.	C	É uma das definições equivalentes
4	Para variável aleatória contínua X , $P(X \leq 3) > P(X < 3)$.	E	São iguais : $P(X = 3) = 0$
5	Probabilidade igual a zero implica que o evento é impossível.	E	Falso no caso contínuo
6	Se X e Y têm correlação nula, então são independentes.	E	Correlação zero exclui só relação linear
7	Sendo X e Y independentes, $\text{Var}(X - Y) = \text{Var}(X) - \text{Var}(Y)$.	E	As variâncias somam também na diferença
8	Em uma tabela de dupla entrada, dividir a célula pelo total da sua linha produz uma probabilidade condicional.	C	O denominador denuncia o tipo

Diagnóstico. Os itens 1, 5 e 6 são as três "recíprocas falsas" da disciplina — afirmações que parecem simétricas e não são. Se você errou algum deles, releia as seções 2.3 e 2.7 antes de seguir.

2.9 Questões reais comentadas — Tópico 2

CEBRASPE · SUSEP 2025 · ITEM 16

Eventos de apólices de automóveis: sinistro com culpa (A); sinistro sem culpa (B); ausência de sinistro (C). T é a variável aleatória **contínua** "tempo de habilitação do condutor (anos)" e D é o evento "tempo de habilitação inferior a 2 anos".

Os eventos A , B e C são mutuamente independentes.

ERRADO. Os três são **mutuamente exclusivos** e exaustivos — uma apólice cai em exatamente uma das três situações. E, precisamente por isso, são **dependentes**: saber que houve sinistro com culpa determina, com certeza, que não houve os outros dois, ou seja, $P(B|A) = 0 \neq P(B)$.

É a troca exclusivo × independente da seção 2.3, e o CEBRASPE a repete em praticamente todo concurso. Sempre que o enunciado descrever categorias que esgotam as possibilidades, desconfie de qualquer item que fale em independência.

CEBRASPE · SUSEP 2025 · ITEM 17

Suponha que a probabilidade de um condutor se envolver em sinistro com culpa seja $P(A) = 0,2$ e que $P(A|D) = 0,4$. Nessa situação, $P(A \cap D) = 0,2 \times P(D)$.

ERRADO. Pela regra do produto, $P(A \cap D) = P(A|D) \times P(D) = 0,4 \times P(D)$.

O item usa a probabilidade **marginal** (0,2) onde a regra exige a **condicional** (0,4). Só seria correto se A e D fossem independentes — hipótese que o próprio enunciado destrói, já que $P(A|D) = 0,4 \neq 0,2 = P(A)$.

Diagnóstico rápido: quando o enunciado fornece a marginal e a condicional com valores diferentes, ele está dizendo, nas entrelinhas, que **os eventos são dependentes** — e qualquer item que trate os dois números como intercambiáveis está errado.

CEBRASPE · SUSEP 2025 · ITENS 18, 19 E 20

18 — A variável aleatória T pode ser caracterizada por uma função de distribuição de probabilidade $P(T = t)$, em que t denota um tempo de habilitação em anos.

19 — Considere $P(A) = 0,2$, $P(B) = 0,1$, $P(C) = 0,7$ e $P(D|A) = 0,3$, $P(D|B) = 0,2$ e $P(D|C) = 0,1$. Com base nessas considerações, conclui-se que 15% dos condutores possuem tempo de habilitação inferior a 2 anos.

20 — Para a variável aleatória T , se $P(D) = P(T < 2) = 0,5$, então $P(T \geq 2) = 0,5$.

18: ERRADO — o enunciado diz expressamente que T é **contínua**, e para variável contínua $P(T = t) = 0$ para **todo** t . Uma função identicamente nula não caracteriza distribuição alguma. A variável é descrita por uma função **densidade**, cuja área — e não cujo valor pontual — representa probabilidade.

19: CERTO — **probabilidade total pura**. Note primeiro que A , B e C formam **partição** ($0,2 + 0,1 + 0,7 = 1$), o que autoriza a fórmula: $P(D) = 0,3(0,2) + 0,2(0,1) + 0,1(0,7) = 0,06 + 0,02 + 0,07 = 0,15 = 15\%$ ✓

20: CERTO — pelo complementar, $P(T \geq 2) = 1 - P(T < 2) = 1 - 0,5 = 0,5$. Como T é **contínua**, $P(T = 2) = 0$ e, portanto, $\geq$ e $>$ dão o mesmo valor — o que torna a passagem legítima. Se T fosse discreta, o item exigiria cuidado com o ponto 2.

Observe a arquitetura do bloco: os itens 18 e 20 cobram a *mesma* propriedade (continuidade implica probabilidade pontual nula) em direções opostas — um a nega, o outro a usa.

CEBRASPE · ANA 2024 · ITEM 17

I — quem estuda com afinco e não cola tem 80% de chance de aprovação. II — quem não estuda e não cola, 5%. III — quem não estuda, cola e não é pego, 95%. IV — quem é pego colando é reprovado. V — quem cola tem 90% de chance de ser pego. VI — quem estuda com afinco não cola. VII — 20% dos candidatos estudam com afinco. VIII — 10% colam.

Sabendo que um candidato foi aprovado, a probabilidade de ser um que não estuda com afinco e não cola na prova é superior a 17,5%.

ERRADO. É Bayes. Monte os caminhos e seus pesos:

- **estuda com afinco** (0,20) → não cola (premissa VI) → aprova 0,80 → **0,160**
- **cola e é pego** ($0,10 \times 0,90 = 0,09$) → reprovado (premissa IV) → **0**
- **cola e não é pego** ($0,10 \times 0,10 = 0,01$) → aprova 0,95 → **0,0095**
- **não estuda e não cola** ($1 - 0,20 - 0,10 = 0,70$) → aprova 0,05 → **0,035**

Probabilidade total de aprovação = $0,160 + 0 + 0,0095 + 0,035 = 0,2045$.

$P(\text{não estuda e não cola} \mid \text{aprovado}) = 0,035/0,2045 \approx 17,1\%$, que **não** é superior a 17,5%.

A armadilha é o limiar. Quem para em "aproximadamente 17%" e não compara com 17,5% marca CERTO. **Regra:** quando o item fixa um valor com casa decimal, ele quase sempre foi escolhido para ficar a milésimos da resposta — leve o cálculo até o fim.

16 — Repetindo-se um grande número de vezes o experimento de selecionar um candidato ao acaso e perguntar se ele estuda com afinco, a frequência relativa do número de casos com resposta afirmativa converge para 20% do total.

18 — O conjunto dos candidatos que estudam com afinco e colam na prova corresponde a um evento impossível no espaço de probabilidades dos candidatos que estudam com afinco.

19 — Um candidato começa a prova somente após lançar sua moeda especial e obter cara em sucessivos lançamentos. Sendo p a probabilidade de cara, a probabilidade de ele iniciar a prova no 15.º lançamento é $P = (1 - p)^{14} p$.

20 — Ao escolher um candidato ao acaso, a probabilidade de ele não ter estudado com afinco, ter colado e ter sido pego é de 10%.

16: CERTO — é a **definição frequentista** de probabilidade (lei dos grandes números) aplicada à premissa VII. A frequência relativa observada converge para a probabilidade teórica, 20%.

18: CERTO — a premissa VI estabelece que quem estuda com afinco não cola; logo a interseção é vazia e, condicionada ao universo "candidatos que estudam com afinco", tem probabilidade zero: **evento impossível**. Repare no rigor da formulação — "no espaço de probabilidades dos candidatos que estudam com afinco" é exatamente a *redução do espaço amostral* da seção 2.4.

19: ERRADO (gabarito oficial). A expressão $(1 - p)^{14} p$ é o modelo geométrico — 14 fracassos seguidos de um sucesso —, que valeria se o critério fosse "*a primeira* cara sair no 15.º lançamento". O enunciado, porém, fala em obter cara em **lançamentos sucessivos**, condição diferente da modelada, e é nessa leitura que o gabarito se apoia. **Item de baixo rendimento para estudo** — depende da interpretação do enunciado, não do conceito; registre apenas o modelo geométrico, que é o conteúdo aproveitável.

20: ERRADO — colar e ser pego tem probabilidade $0,10 \times 0,90 = 9\%$, não 10%. (A primeira condição, "não ter estudado com afinco", não altera o cálculo, pois colar já implica não estudar com afinco, pela premissa VI.) O "10%" do item é a probabilidade de *colar*, sem o filtro de ser pego — **é um dado do enunciado reaproveitado no lugar errado**, padrão listado no radar da seção 4.3.

A probabilidade de um documento em **papel** ser preenchido corretamente é $P(C|A) = 0,4$; por **aplicativo**, $P(C|B) = 0,7$. Cada interessado opta por apenas uma modalidade, e o preenchimento por aplicativo representa 90% dos casos. Qual é $P(C)$?

A 0,28 **B** 0,40 **C** 0,55 **D** 0,67 **E** 0,70

Gabarito: D. "Cada interessado opta por **apenas uma** modalidade" é a frase que garante a **partição** — sem ela a probabilidade total não se aplicaria.

$$P(C) = 0,4(0,10) + 0,7(0,90) = 0,04 + 0,63 = \mathbf{0,67}$$

As alternativas mapeiam os erros: **C** (0,55) é a *média simples* de 0,4 e 0,7 — o erro de quem ignora a ponderação; **A** (0,28) é $0,4 \times 0,7$, quem multiplica em vez de somar os caminhos; **B** e **E** são as condicionais isoladas.

É o mesmo teorema do item 19 da SUSEP, em bancas de formatos diferentes — prova de que a estrutura, e não a roupagem, é o que se deve estudar.

RJ 58 — Eventos independentes com $P(G) = 0,4$ e $P(H) = 0,6$; a alternativa correta afirma que $P(G^c \cap H^c) = 0,24$ (gabarito **D**).

RN 55 — Eventos independentes X e Y , com $P(X \cup Y) = 0,8$ e $P(X) = 0,5$. Qual é $P(Y)$? (gabarito **A**, 0,6)

RJ 58: pela propriedade da herança (seção 2.5), se G e H são independentes, os complementares também são. Logo $P(G^c \cap H^c) = (1 - 0,4)(1 - 0,6) = 0,6 \times 0,4 = \mathbf{0,24}$. Caminho alternativo, por De Morgan: $1 - P(G \cup H) = 1 - (0,4 + 0,6 - 0,24) = 1 - 0,76 = 0,24 \checkmark$

RN 55: combine **adição** e **independência** — $0,8 = 0,5 + P(Y) - 0,5 \cdot P(Y) \Rightarrow 0,3 = 0,5 \cdot P(Y) \Rightarrow P(Y) = \mathbf{0,6}$.

Padrão a memorizar: quando o enunciado diz "independentes" e fornece a **união**, a rota é sempre substituir $P(A \cap B)$ por $P(A) \cdot P(B)$ dentro da regra da **adição**, obtendo uma equação de primeiro grau na incógnita.

Além da tabela de X (seção 1.13), o caderno traz V e W , variáveis **contínuas e mutuamente independentes**, com $P(V \leq 0) = 0,3$ e $P(W \leq 0) = 0,7$.

27 — $P(X = 1) = 0,2$.

28 — X segue uma distribuição contínua, pois c é uma constante real positiva.

32 — O primeiro quartil da variável V é inferior a zero.

33 — A probabilidade de ocorrência simultânea dos eventos $V \leq 0$ e $W \leq 0$ é igual a 0,21.

34 — Em relação aos eventos $V \leq 0$ e $W \leq 0$, é correto afirmar que a probabilidade condicional $P(V \leq 0 \mid W \leq 0)$ deve ser superior a 0,3.

27: **CERTO** — $3c = 3/15 = 0,2$.

28: **ERRADO** — o suporte $\{-2, -1, 0, +1, +2\}$ é finito: a variável é **discreta**. A natureza da constante c nada tem a ver com a classificação — **é um caso puro de "afirmação + justificativa" em que a justificativa é verdadeira mas irrelevante**, e a conclusão, falsa.

32: **CERTO** — a acumulada de V já vale 0,3 em zero. Como $0,3 > 0,25$, o ponto em que a acumulada cruza 25% está **antes** de zero; logo $Q_1 < 0$. Perceba que este item é de *descritiva* (separatriz) dentro de um bloco de probabilidade — exatamente o que o item 14.1.2 do edital autoriza.

33: **CERTO** — independência: $0,3 \times 0,7 = 0,21$.

34: **ERRADO** — sendo independentes, $P(V \leq 0 \mid W \leq 0) = P(V \leq 0) = 0,3$ — *igual* a 0,3, e não superior. Item que se resolve **pela definição, sem conta**: condicionar em evento independente não altera a probabilidade. Note o rigor do "superior a": se o item dissesse "igual ou superior", seria CERTO.

População de 20 elementos distribuídos em seis conglomerados: I = {1,2,3,4}; II = {5,6,7,8}; III = {9,10,11,12}; IV = {13,14,15}; V = {16,17}; VI = {18,19,20}. Amostragem aleatória por conglomerados de tamanho $n = 2$.

Se $P(E_6)$ e $P(E_7)$ representam, respectivamente, as probabilidades de seleção dos elementos 6 e 7, então E_6 e E_7 são eventos independentes.

ERRADO. Os elementos 6 e 7 pertencem ao **mesmo conglomerado** (o II). Se um entra na amostra, o outro entra necessariamente — $P(E_7 \mid E_6) = 1$, enquanto $P(E_7) = 2/6 = 1/3$. Como $1 \neq 1/3$, os eventos são **dependentes** — e da forma mais extrema possível.

Este item é a articulação entre os dois tópicos: o desenho amostral *cria* estrutura de dependência entre observações. É a mesma razão pela qual a AAS sem reposição gera observações dependentes (TC/DF 2020, item 62) e pela qual a amostragem por conglomerados costuma perder precisão.

TÓPICO 3 · AMOSTRAGEM

Corresponde aos itens 4 e 4.1 do programa: "Amostragem. Amostragem aleatória simples, estratificada, sistemática e por conglomerados."

3.1 Por que amostrar — e o vocabulário que sustenta o tópico

Amostrar é observar uma parte para concluir sobre o todo. Em fiscalização tributária isso não é uma opção teórica: auditar todas as notas fiscais de um estado é materialmente impossível. As quatro razões clássicas para amostrar em vez de recensear são **custo**, **tempo**, **viabilidade operacional** (populações grandes ou dispersas) e, contraintuitivamente, **qualidade** — uma amostra bem executada costuma ter menos erros de medição do que um censo mal executado, porque permite concentrar recursos de treinamento e supervisão.

CONCEITO	DEFINIÇÃO	NOTAÇÃO / EXEMPLO
População (universo)	Conjunto de todos os elementos de interesse	tamanho N
População-alvo	A que se quer estudar	Todos os contribuintes de ICMS de AL
População amostrada	A que efetivamente pode ser sorteada, dado o cadastro disponível	Os inscritos no cadastro estadual
Sistema de referência (cadastro)	A lista de onde se sorteia	Cadastro de contribuintes
Amostra	Subconjunto efetivamente observado	tamanho n
Censo	Observação de todos os elementos	$n = N$
Unidade amostral	O elemento que é efetivamente sorteado	A obra, o domicílio, o município...
Unidade de análise	Aquilo sobre o que se mede a variável	Pode diferir da unidade amostral
Fração amostral	$f = n / N$	Proporção da população na amostra

FRAÇÃO AMOSTRAL: O DENOMINADOR É O TAMANHO DA POPULAÇÃO

O CEBRASPE derrubou candidato exatamente aqui — TCE/RN 2025, item 74: "a fração amostral referente a cada categoria é igual a 1/100, em que o denominador corresponde ao **tamanho da amostra**" — **ERRADO**. Fração amostral é **amostra sobre população**. E o erro paralelo do mesmo bloco, item 73, confunde **unidade amostral** (a obra sorteada) com **estrato** (a categoria de obra).

3.2 Parâmetro, estimador e propriedades desejáveis

	PARÂMETRO	ESTATÍSTICA / ESTIMADOR
Refere-se a	A população	A amostra
Natureza	Valor fixo, constante e desconhecido	Variável aleatória — muda a cada amostra sorteada
Símbolos	$\mu, \sigma^2, \sigma, p, N$	$\bar{x}, s^2, s, \hat{p}, n$

Que o estimador seja **variável aleatória** é o ponto conceitual do tópico: sortear outra amostra produz outro $\bar{x}$. A distribuição desses possíveis valores é a **distribuição amostral**, e seu desvio padrão é o **erro padrão** — que mede a precisão do estimador.

PROPRIEDADE	SIGNIFICA
Não viesado (não tendencioso)	$E(\text{estimador}) = \text{parâmetro}$. Em média, acerta. É por isso que s^2 divide por $n - 1$.
Consistente	Converge para o parâmetro à medida que n cresce
Eficiente	Entre os não viesados, é o de menor variância

3.3 Erro amostral × erro não amostral

	ERRO AMOSTRAL	ERRO NÃO AMOSTRAL
Origem	Observar apenas parte da população — é inerente ao ato de amostrar	Falhas de execução: não resposta, cobertura deficiente do cadastro, erro de medição, erro de digitação, viés do entrevistador, resposta falsa
Depende do plano amostral?	Sim — o desenho e o tamanho n o determinam	Não; ocorre inclusive em censo
Pode ser mensurado?	Sim , por métodos estatísticos (erro padrão, margem de erro)	Difícilmente ; em geral não é quantificável
Aumentar n resolve?	Reduz	Não — e pode até agravar, se a coleta perder qualidade
Como se combate	Desenho amostral e tamanho de amostra	Treinamento, supervisão, crítica dos dados, redução da não resposta

O item 7 do ANEEL 2025 **inverteu exatamente estas duas colunas** e foi dado como ERRADO. Guarde a tabela em pares opostos: amostral = *depende do plano + mensurável + cai com n* ; não amostral = *independe do plano + dificilmente mensurável + não cai com n* .

3.4 Amostragem probabilística × não probabilística

O edital nomina quatro técnicas — todas **probabilísticas**. Mas as não probabilísticas aparecem como alternativa errada e precisam ser reconhecidas.

GRUPO	TÉCNICAS	CARACTERÍSTICA DEFINIDORA
Probabilística (aleatória)	Aleatória simples, sistemática, estratificada, por conglomerados (as quatro do edital), além da PPT (probabilidade proporcional ao tamanho)	Todo elemento tem probabilidade conhecida e não nula de ser selecionado — é isso que permite calcular o erro amostral
Não probabilística (não aleatória)	Por conveniência (ou acidental), por julgamento (intencional), por cotas, bola de neve	A seleção depende do julgamento do pesquisador; não permite calcular erro amostral nem generalizar formalmente

NÃO CONFUNDA AMOSTRAGEM POR COTAS COM ESTRATIFICADA

Ambas dividem a população em grupos e fixam quantos elementos vêm de cada um. A diferença é **como se escolhe dentro do grupo**: na **estratificada**, por sorteio aleatório (é probabilística); nas **cotas**, por conveniência do entrevistador (não é probabilística). Alternativa que descreva "o entrevistador aborda pessoas até completar 30 homens e 30 mulheres" é **cotas**, não estratificada.

3.5 Amostragem aleatória simples (AAS)

É o plano de referência, contra o qual todos os outros são comparados. Definição rigorosa: **todo subconjunto de tamanho n tem a mesma probabilidade de ser a amostra selecionada** — o que implica, mas é mais forte do que, "todo elemento tem a mesma probabilidade de entrar".

Procedimento

1. Numerar todos os N elementos do cadastro, de 1 a N .
2. Sortear n números por processo aleatório (tabela de números aleatórios, gerador computacional).
3. Observar os elementos correspondentes.

	COM REPOSIÇÃO	SEM REPOSIÇÃO
O elemento pode repetir?	Sim	Não
Observações independentes?	Sim	Não — cada retirada altera o que resta
Var($\bar{x}$)	σ^2 / n	$\frac{\sigma^2}{n} \cdot \frac{N - n}{N - 1}$
Precisão	Menor	Maior — o fator de correção é sempre < 1
Uso prático	Modelagem teórica	É o que se faz na prática

FATOR DE CORREÇÃO PARA POPULAÇÃO FINITA (FCPF)

O termo $(N - n)/(N - 1)$ é sempre menor que 1: amostrar **sem** reposição é sempre **mais preciso**, porque não se "desperdiça" observação repetindo elemento já visto. Dois casos-limite valem memorização:

- Se $n = N$ (censo), o fator é zero $\rightarrow$ variância zero: não há erro amostral em um censo.
- Se N é muito grande em relação a n , o fator tende a 1 e a distinção deixa de importar. A regra prática é **desprezar o FCPF quando $f = n/N < 5\%$** .

AAS SEM REPOSIÇÃO — O CÁLCULO QUE DECIDIU O ITEM 60 DO TC/DF 2020

População de $N = 1.000$ indivíduos, amostra de $n = 100$ **sem reposição**, desvio padrão populacional $\sigma = 2$ anos. Qual a variância de $\bar{x}$?

Passo 1 — sem a correção: $\sigma^2/n = 4/100 = 0,04$.

Passo 2 — o FCPF: $(1.000 - 100)/(1.000 - 1) = 900/999 = 0,9009$.

Passo 3 — variância corrigida: $0,04 \times 0,9009 \approx 0,036$.

Por que isso é o item inteiro: o enunciado perguntava se a variância era "inferior a 0,04". Sem a correção, dá *exatamente* 0,04 e o item seria ERRADO; com a correção, dá 0,036 e o item é CERTO. **O fator de correção é o item.** Note também que $f = 10\% > 5\%$, ou seja, aqui o FCPF **não** podia ser desprezado.

Erro padrão de uma proporção

$$\text{erro padrão de } \hat{p} = \sqrt{\frac{p(1 - p)}{n}} \leq \frac{0,5}{\sqrt{n}}$$

O produto $p(1 - p)$ é máximo em $p = 0,5$, valendo 0,25

Consequência prática memorizável: **com $n = 100$, o erro padrão de uma proporção nunca passa de 5%**; com $n = 400$, nunca passa de 2,5%. Foi exatamente o que decidiu o item 75 do TCE/RN 2025. E note a implicação de política amostral: **para dividir o erro por dois é preciso quadruplicar a amostra**, porque o erro cai com $\sqrt{n}$.

3.6 Amostragem sistemática

Ordena-se a população em uma lista e seleciona-se de k em k elementos, sorteando-se aleatoriamente apenas o **primeiro**.

Procedimento

1. Calcule o **intervalo** (ou salto) $k = N / n$.
2. Sorteie a **partida aleatória** r , um número entre 1 e k .
3. A amostra é $r, r + k, r + 2k, \dots, r + (n - 1)k$.

AUDITORIA DE NOTAS FISCAIS POR SISTEMÁTICA

Situação: 1.000 notas fiscais emitidas; auditar 50.

Passo 1. $k = 1.000/50 = 20$.

Passo 2. Sorteie-se r entre 1 e 20 — suponha $r = 7$.

Passo 3. Auditam-se as notas 7, 27, 47, 67, ..., 987. São 50 notas.

Probabilidade de seleção: cada nota tem probabilidade $1/k = 1/20 = 5\%$ — igual para todas, o que confirma o caráter probabilístico da técnica.

VANTAGENS, E O RISCO CARACTERÍSTICO

- **Vantagem operacional:** exige um único sorteio; dispensa numerar toda a população de antemão; é a técnica natural de fiscalização em fluxo ("a cada 20 notas, audite uma").
- **Vantagem estatística:** espalha a amostra uniformemente pela lista, o que a torna, em geral, mais precisa que a AAS quando a lista está ordenada por alguma variável correlacionada ao objeto de estudo (funciona como uma estratificação implícita).
- **Risco característico — a periodicidade.** Se a lista tiver ciclo coincidente com k , a amostra fica gravemente enviesada. Exemplo: listar vendas por dia e adotar $k = 7$ selecionaria **sempre o mesmo dia da semana**. É a única desvantagem que a banca cobra.
- Se N/n não for inteiro, arredonda-se k e admite-se pequena variação no tamanho final da amostra.

3.7 Amostragem estratificada

A população é dividida em **estratos** — subgrupos **internamente homogêneos** e heterogêneos entre si quanto à variável de interesse (faixa de faturamento, ramo de atividade, região, regime tributário). **Todos os estratos entram no estudo** e, dentro de cada um, faz-se uma AAS.

Por que ela ganha precisão

A variância do estimador estratificado depende apenas da variabilidade **dentro** dos estratos — a variabilidade **entre** estratos é eliminada pelo próprio desenho, já que todos são representados na proporção definida. Quanto mais homogêneo for cada estrato, menor a variância total. Por isso a regra de construção: **estratos homogêneos por dentro, diferentes entre si**.

As três alocações

ALOCACÃO	REGRA	QUANDO USAR
Uniforme (igual)	mesmo n_h em todos os estratos	Estratos de tamanhos semelhantes, ou quando o objetivo é comparar estratos entre si
Proporcional	n_h proporcional a N_h	Padrão; reproduz a composição da população — gera amostra autoponderada
Ótima (Neyman)	n_h proporcional a $N_h \cdot S_h$	Minimiza a variância para um custo fixo: manda amostra para onde há variabilidade

Proporcional: $n_h = n \cdot \frac{N_h}{N}$ **Neyman:** $n_h = n \cdot \frac{N_h S_h}{\sum N_i S_i}$

S_h é o **desvio padrão** do estrato — se o enunciado der a variância, extraia a raiz antes

AS TRÊS ALOCAÇÕES SOBRE A MESMA POPULAÇÃO

Cadastro de 10.000 contribuintes, amostra total $n = 200$, em três estratos:

ESTRATO	N_H	S_H	$N_H S_H$	UNIFORME	PROPORCIONAL	NEYMAN
I — grandes	2.000	10	20.000	67	40	40
II — médios	3.000	20	60.000	67	60	120
III — pequenos	5.000	4	20.000	66	100	40
Total	10.000	—	100.000	200	200	200

Conta de Neyman, estrato II: $200 \times (60.000/100.000) = 120$.

A lição: o estrato III é o **maior** da população (metade dela) e recebe a maior amostra na alocação proporcional — mas, por ser o mais **homogêneo** ($S = 4$), recebe a **menor** amostra sob Neyman. *Neyman manda amostra para onde há variabilidade, não para onde há gente.* Se todos os estratos tivessem o mesmo desvio padrão, Neyman e proporcional coincidiriam.

3.8 Amostragem por conglomerados

A população é dividida em **conglomerados** (clusters) — agrupamentos **naturais**, tipicamente geográficos ou institucionais: municípios, bairros, quarteirões, domicílios, escolas, empresas. Sorteiam-se os **conglomerados**, e não os elementos individuais.

MODALIDADE	PROCEDIMENTO	EXEMPLO
Um estágio	Nos conglomerados sorteados, observam-se todos os elementos (censo interno)	Sortear 10 municípios e fiscalizar todos os estabelecimentos deles
Dois estágios	Nos conglomerados sorteados, faz-se nova amostragem dos elementos	Sortear 10 municípios e, em cada um, sortear 50 estabelecimentos

O ideal técnico é o oposto do da estratificada: cada conglomerado deve ser uma "**mini-população**" — **heterogêneo por dentro**, refletindo toda a diversidade do universo, e **semelhante aos demais conglomerados**. Quando os conglomerados são internamente homogêneos (o que é comum na prática, pois vizinhos se parecem), a técnica perde muita precisão.

VANTAGENS

Custo e logística — concentra o trabalho de campo geograficamente

Dispensa cadastro completo de **todos** os elementos — basta a lista de conglomerados

DESVANTAGENS

Menor precisão que a AAS de mesmo tamanho, em regra

Exige amostra maior para atingir a mesma precisão

EFEITO DO DESENHO (DEFF)

Compara a variância obtida pelo plano adotado com a que se obteria por AAS de mesmo tamanho: $deff = \text{Var}(\text{plano}) / \text{Var}(\text{AAS})$. Em regra, **conglomerados têm $deff > 1$** (perde precisão) e **estratificada tem $deff < 1$** (ganha precisão). É a formalização das linhas "efeito na precisão" do quadro comparativo seguinte.

POR QUE CONGLOMERADOS PERDEM PRECISÃO — A CORRELAÇÃO INTRACLASSE

Elementos do mesmo conglomerado **se parecem**: vizinhos têm renda parecida, empresas do mesmo município enfrentam a mesma fiscalização. Essa semelhança interna é medida pela **correlação intraclasses**. Quanto maior ela for, **menos informação nova** cada elemento adicional do mesmo conglomerado traz — entrevistar o segundo morador de um domicílio acrescenta bem menos que entrevistar um morador de outro domicílio. No limite, se todos dentro do conglomerado fossem idênticos, observar 30 deles valeria tanto quanto observar **um**.

É por isso que uma amostra por conglomerados de tamanho 1.000 pode ter a precisão de uma AAS de 300 — e é daí que vem o **efeito do desenho**. A estratificada faz o movimento oposto: como os estratos são homogêneos por dentro e *diferentes entre si*, garantir presença de todos elimina uma fonte inteira de variabilidade.

3.9 O quadro que decide os itens de amostragem

1 · Aleatória simples

sorteiam-se os elementos, um a um



Todo subconjunto de tamanho n tem a mesma chance. Sem estrutura: o sorteio é disperso.

2 · Sistemática

sorteia-se só o primeiro; depois, de k em k



O padrão é regular — e é essa regularidade que gera viés se a lista tiver periodicidade igual a k .

3 · Estratificada


todos os estratos entram; sorteio dentro de cada um



Nenhum estrato fica de fora. O tom forte é o elemento sorteado dentro do seu próprio estrato.

4 · Por conglomerados

sorteia-se o grupo inteiro; nem todos entram



Sorteado o grupo B, todos os seus elementos entram; A e C ficam integralmente de fora.

Leitura. Compare os painéis 3 e 4, que é onde a prova mora. Na **estratificada**, as três faixas de cor aparecem todas — nenhum grupo fica de fora — e o sorteio recai sobre *elementos*. Nos **conglomerados**, dois dos três grupos ficam **inteiramente** fora, e o sorteio recai sobre o *grupo*. Daí decorre tudo: a dependência entre elementos do mesmo conglomerado, a probabilidade condicional igual a 1 do item 41 da CGE/RJ, e o fato de o tamanho da amostra ser contado em **grupos**, não em elementos.

ESTRATIFICADA × CONGLOMERADOS

	ESTRATIFICADA	CONGLOMERADOS
O que se sorteia	Os elementos , dentro de cada estrato	Os grupos inteiros
Todos os grupos entram?	Sim — todos os estratos são amostrados	Não — só os conglomerados sorteados
Homogeneidade desejada	Dentro do estrato (heterogêneo entre estratos)	Entre conglomerados (heterogêneo dentro)
Unidade amostral	O elemento	O conglomerado (no 1.º estágio)
Como se formam os grupos	Por critério analítico (faixa, ramo, porte)	Por proximidade natural (geográfica, institucional)
Efeito na precisão	Em regra ganha ($deff < 1$)	Em regra perde ($deff > 1$)
Motivação principal	Precisão e representação de subgrupos	Custo e viabilidade operacional

Teste de dois segundos: pergunte-se "o sorteio recaiu sobre elementos ou sobre grupos?". Se sortearam **municípios, domicílios** ou **quarteirões** e depois observaram tudo o que havia dentro, é **conglomerado**. Se dividiram por categoria analítica e tiraram uma amostra **de cada** categoria, é **estratificada**.

TÉCNICA	ASSINATURA NO ENUNCIADO	PALAVRA-CHAVE
Aleatória simples	"sorteou-se aleatoriamente n elementos entre os N "	sorteio direto
Sistemática	"a cada k elementos da lista, selecionou-se um"	intervalo / a cada
Estratificada	"dividiu-se por porte/região e sorteou-se n_h de cada grupo"	de cada
Conglomerados	"sortearam-se m municípios e observaram-se todos os elementos deles"	todos os que estão dentro

3.10 Teste rápido — Tópico 3

Oito itens no formato da prova, todos construídos sobre confusões que a banca já explorou.

#	ITEM	C/E	POR QUÊ
1	Na amostragem estratificada, sorteiam-se os estratos e observam-se todos os elementos dos estratos sorteados.	E	Isso é conglomerados ; na estratificada todos os estratos entram
2	Na amostragem por conglomerados, os grupos devem ser internamente homogêneos.	E	Invertido: devem ser heterogêneos por dentro; a homogeneidade interna é o ideal do estrato
3	Na amostragem sistemática, sorteia-se aleatoriamente apenas o primeiro elemento.	C	Depois, de k em k
4	Amostragem por cotas é uma técnica probabilística, pois fixa previamente o número de elementos de cada grupo.	E	Dentro do grupo a escolha é por conveniência
5	Em AAS sem reposição, as observações são independentes.	E	Só a AAS com reposição gera independência

#	ITEM	C/E	POR QUÊ
6	O fator de correção para população finita reduz a variância do estimador da média.	C	É sempre menor que 1
7	Na alocação de Neyman, o estrato mais numeroso recebe sempre a maior amostra.	E	Recebe amostra quem tem variabilidade ; foi o gabarito da Q. 60 da SEFAZ/RJ
8	Aumentar o tamanho da amostra reduz tanto o erro amostral quanto o não amostral.	E	Reduz apenas o amostral

Diagnóstico. Os itens 1 e 2 são a mesma confusão vista de dois ângulos — se você errou qualquer um, volte ao quadro da seção 3.9 e à figura das quatro técnicas antes de seguir para as questões reais. Essa é, isoladamente, a distinção mais lucrativa de todo o programa.

3.11 Questões reais comentadas — Tópico 3

CEBRASPE · ANEEL 2025 · ITENS 7, 8 E 9

"Considerando a importância das técnicas de amostragem para diversas finalidades, como fiscalização, auditoria, experimentação de mercado, definição de tarifas, entre outras, julgue os itens a seguir."

7 — Os erros amostrais não dependem do plano amostral e são de difícil controle prático, ao passo que os erros não amostrais geralmente são facilmente mensurados por métodos estatísticos.

8 — Na amostragem por conglomerados, retira-se uma amostra aleatória de subconjuntos naturais (conglomerados) e, em seguida, tomando-se os conglomerados selecionados, realiza-se uma análise de todos os elementos (censo) ou uma nova amostragem.

9 — O processo de análise estatística, no contexto da amostragem, envolve três etapas principais: treinamento, validação e teste.

7: ERRADO — o item **inverte as duas colunas** da tabela da seção 3.3. O erro amostral *depende* do plano amostral e *é* mensurável estatisticamente; o erro não amostral é que é de difícil mensuração. Repare que o item comete **dois** erros simétricos — e bastaria um.

8: CERTO — é a definição literal, e note que ela cobre **as duas modalidades**: censo interno (um estágio) ou nova amostragem (dois estágios). Esta redação é praticamente o enunciado-padrão do CEBRASPE para conglomerados; vale decorá-la.

9: ERRADO — treinamento, validação e teste é vocabulário de **aprendizado de máquina** (divisão de conjunto de dados para modelagem), não de amostragem. Item plantado para o candidato que estudou ciência de dados e não estatística clássica — situação frequente neste concurso, em que a P2 tem 20 itens de Ciência de Dados.

Um tribunal de contas quer estimar percentuais de obras adiantadas e atrasadas em relação ao cronograma. Cada obra está classificada em uma **única** categoria. Devido à grande quantidade de categorias, a equipe concentrou o estudo em quatro delas — (i) portos e aeroportos, (ii) energia elétrica, (iii) estradas e rodovias e (iv) saneamento básico. **De cada uma** dessas categorias será selecionada uma amostra aleatória simples de **100 obras**.

- 71 — A probabilidade de seleção de cada obra na amostra é igual entre as categorias, uma vez que foram selecionadas 100 obras de cada uma delas.
- 72 — O procedimento descrito caracteriza uma amostragem por conglomerados, pois foram selecionados grupos específicos de obras para compor a amostra.
- 73 — Cada categoria de obra constitui uma unidade amostral.
- 74 — A fração amostral referente a cada categoria de obras é igual a $1/100$, em que o denominador corresponde ao tamanho da amostra.
- 75 — Na estimação do percentual de obras adiantadas no saneamento básico por amostragem aleatória simples, o erro padrão do estimador deve ser, no máximo, igual a 10%.

Diagnóstico, antes de tudo: as categorias são **estratos** (grupos analíticos, todos amostrados, com AAS dentro de cada um) e a alocação é **uniforme** ($n_h = 100$ em todos). Fixado isso, os cinco itens caem.

71: ERRADO — n_h é igual, mas N_h não. A probabilidade de seleção de cada obra é $100/N_h$, portanto **maior nos estratos menores**. Sob alocação uniforme, a amostra **não** é autoponderada — só a proporcional é.

72: ERRADO — a troca clássica. Em conglomerados, sortear-se-iam *categorias inteiras*, e algumas ficariam de fora; aqui as quatro entram e o sorteio recai sobre as **obras**. Observe ainda a estrutura "afirmação + **pois**" da seção 0.4: a justificativa é verdadeira (grupos específicos foram, sim, escolhidos), mas a conclusão é falsa.

73: ERRADO — a unidade amostral é a **obra** (é ela que se sorteia); a categoria é o **estrato**. Confusão diretamente coberta pela tabela da seção 3.1.

74: ERRADO — fração amostral é n_h/N_h , e o denominador é o tamanho do estrato **na população**, não o da amostra. O item erra a definição e ainda a explicita, tornando-se duplamente errado.

75: CERTO — erro padrão de proporção com $n = 100$: $\sqrt{p(1-p)/100} \leq 0,5/10 = 5\%$, que é, sim, "no máximo 10%". A cota superior da seção 3.5 resolve o item sem conhecer p .

Bloco exemplar: quatro itens ERRADOS seguidos de um CERTO, todos derivados do *mesmo* parágrafo. Identificar a técnica corretamente no primeiro segundo entrega cinco itens — e errar a identificação custa cinco.

População de 20 elementos em seis conglomerados: I = {1,2,3,4}; II = {5,6,7,8}; III = {9,10,11,12}; IV = {13,14,15}; V = {16,17}; VI = {18,19,20}. Amostragem aleatória por conglomerados de tamanho $n = 2$.

- 41 — Sabendo-se que o elemento 12 se encontra na amostra, é correto afirmar que a probabilidade de seleção do elemento 9 é igual a 1.
- 42 — A referida amostra por conglomerados deve ser constituída exatamente por dois elementos, por exemplo, {13, 17}.

41: CERTO — o elemento 12 pertence ao conglomerado III. Se ele está na amostra, é porque o conglomerado III **inteiro** foi sorteado; e o elemento 9 também pertence ao III. Logo $P(\text{seleção do 9} \mid 12 \text{ na amostra}) = 1$. É probabilidade condicional aplicada a desenho amostral.

42: ERRADO — $n = 2$ é o número de **conglomerados** sorteados, não de elementos. Sorteando dois conglomerados, a amostra terá entre 4 e 8 elementos, conforme os grupos sorteados. Além disso, {13, 17} mistura elementos dos conglomerados IV e V, o que o desenho não permite — nem todos os elementos de nenhum dos dois grupos estão presentes.

Núcleo do bloco: em conglomerados, a **unidade sorteada é o grupo**, e todos os elementos de um mesmo grupo entram ou saem **juntos**. Daí decorrem os três itens: a dependência (item 40, comentado na seção 2.9), a condicional igual a 1 (41) e o tamanho da amostra (42).

Amostra aleatória simples, **sem reposição**, de tamanho 100, retirada de uma população de 1.000 indivíduos, com o objetivo de estimar a média μ das idades. O desvio padrão populacional é 2 anos.

60 — A variância do estimador $\bar{x}$ é inferior a 0,04.

61 — Se $(x_1, \dots, x_{100})$ representa uma possível realização de $X_1, \dots, X_{100}$, então $P(X_1 = x_1, \dots, X_{100} = x_{100}) = 0,1$.

62 — No plano amostral em questão, as variáveis aleatórias $X_1, \dots, X_{100}$ são independentes.

60: CERTO — com o FCPF: $(4/100) \times (900/999) \approx 0,036 < 0,04$. Sem a correção daria exatamente 0,04, e o item seria ERRADO — o **fator de correção é o item** (cálculo completo na seção 3.5).

61: ERRADO — 0,1 é a **fração amostral** (100/1.000), não a probabilidade de uma realização específica, que é ordens de grandeza menor (1 dividido pelo número de arranjos possíveis de 100 elementos entre 1.000). É o padrão "número do enunciado reaproveitado no lugar errado".

62: ERRADO — na AAS **sem reposição** as observações **não** são independentes: cada retirada altera a composição do que resta e, portanto, a distribuição da retirada seguinte. Apenas a AAS **com reposição** gera independência. Note que este item e o 60 são duas faces da mesma propriedade: é justamente a dependência introduzida pela não reposição que produz o fator de correção e reduz a variância.

RJ 59 — Para fiscalizar obrigações acessórias, os auditores selecionaram aleatoriamente **10 municípios** dentre os 92 existentes e incluíram na amostra **todos** os estabelecimentos comerciais localizados em cada município sorteado.

RN 52 — Em levantamento domiciliar, foi selecionada aleatoriamente uma amostra de **780 domicílios**; todos os residentes desses domicílios foram incluídos na pesquisa, totalizando 2.155 pessoas entrevistadas.

Ambos: amostragem por conglomerados (RJ, gabarito B; RN, gabarito E) — e, mais precisamente, **em um estágio**, pois há censo dentro do conglomerado selecionado.

A assinatura é idêntica nos dois enunciados: **sorteia-se uma unidade natural (município, domicílio) e observa-se tudo o que há dentro dela**.

Detalhe decisivo no RN: a unidade amostral é o **domicílio** (780), não a pessoa (2.155). A alternativa que oferecia "amostragem aleatória simples, cuja unidade amostral primária é o residente, perfazendo total amostral de 2.155 pessoas" existia justamente para punir quem confunde *unidade amostral* com *unidade de análise*.

Convertido para certo/errado — que é o formato de Alagoas — a mesma situação viraria: "o plano descrito caracteriza amostragem estratificada, pois os domicílios foram agrupados previamente" (ERRADO) ou "trata-se de amostragem por conglomerados em um estágio, com censo interno" (CERTO).

Planejamento de amostragem aleatória estratificada, em que V denota a **variância** populacional da variável de interesse: estrato I — $N = 1.000$, $V = 25$; estrato II — $N = 1.000$, $V = 9$; estrato III — $N = 2.000$, $V = 1$.

Se o tamanho total da amostra for igual a 100, considerando-se a **alocação ótima de Neyman**, o tamanho da amostra referente ao estrato III será igual a

A 20 B 30 C 40 D 50 E 60

Gabarito: A. Neyman pondera por $N_h \cdot S_h$, e S_h é o **desvio padrão** — extraia a raiz das variâncias: 5, 3 e 1.

· I: $1.000 \times 5 = 5.000$ · II: $1.000 \times 3 = 3.000$ · III: $2.000 \times 1 = 2.000 \rightarrow$ soma = 10.000

· $n_{III} = 100 \times (2.000/10.000) = 20$

As armadilhas, uma a uma: quem usa a variância sem tirar a raiz obtém $100 \times [2.000/(25.000 + 9.000 + 2.000)] \approx 5,6$; quem faz alocação **proporcional** obtém $100 \times (2.000/4.000) = 50$ — a alternativa **D**, plantada exatamente para isso.

Leitura conceitual: o estrato III é o **maior** em população (metade dela) e ainda assim recebe a **menor** amostra, porque é o mais homogêneo ($V = 1$). É a lógica de Neyman em estado puro — a mesma do exemplo resolvido da seção 3.7.

As cinco alternativas do enunciado do RN (780 domicílios, 2.155 residentes) formam, na prática, um **catálogo de definições erradas** de amostragem. Vale estudá-las uma a uma.

A "amostragem sistemática, na qual todos os residentes dos domicílios sorteados foram selecionados de forma sistemática" — **errada**: não há intervalo k nem partida aleatória; "de forma sistemática" no sentido coloquial não é a técnica.

B "AAS, cuja unidade amostral primária é o residente, totalizando 2.155 pessoas" — **errada**: confunde unidade amostral (domicílio) com unidade de análise (pessoa).

C "estratificada com alocação proporcional ao número de residentes por domicílio" — **errada**: não há estratos; e a alocação proporcional distribui a amostra *entre estratos*, não dentro de domicílios.

D "estratificada com alocação ótima, por se tratar de método autoponderado" — **errada** duas vezes: não é estratificada, e alocação ótima **não** é autoponderada (a proporcional é que o é).

E "amostragem por conglomerados, em que 780 domicílios foram selecionados aleatoriamente, sendo todos os seus residentes incluídos" — **correta**.

Por que este exercício vale: em formato certo/errado, cada uma dessas alternativas viraria um item independente. Saber por que *cada* uma está errada é saber responder cinco itens.

4.1 Formulário completo

BLOCO	FÓRMULA	LEITURA / CUIDADO
Descritiva — posição	$\bar{x} = \Sigma f_i x_i / \Sigma f_i$	Média; em classes, x_i é o ponto médio
	$\Sigma(x_i - \bar{x}) = 0$	A soma dos desvios é sempre nula
	$H \leq G \leq A$	Harmônica $\leq$ geométrica $\leq$ aritmética
	$Md = l + [(n/2 - F_{\text{ant}})/f] \cdot h$	Mediana em classes
	$Q_i = l + [(i \cdot n/4 - F_{\text{ant}})/f] \cdot h$	Quartis (decis: $i \cdot n/10$; percentis: $i \cdot n/100$)
	$Mo = l + [\Delta_1/(\Delta_1 + \Delta_2)] \cdot h$	Moda de Czuber
	$Mo < Md < \bar{x}$	Assimetria positiva (à direita)
	$Q_2 = D_5 = P_{50} = Md$	Equivalências das separatrizes
	$k = 1 + 3,322 \cdot \log_{10}(n)$	Regra de Sturges (nº de classes)
Descritiva — dispersão e forma	$s^2 = \Sigma(x_i - \bar{x})^2 / (n - 1)$	Variância amostral ; populacional divide por N
	$\sigma^2 = E(X^2) - [E(X)]^2$	Atalho de cálculo
	$CV = s/\bar{x}$	Único adimensional; compara escalas diferentes
	$AIQ = Q_3 - Q_1$	Dispersão robusta
	$A_p = (\bar{x} - Mo)/s \mid 3(\bar{x} - Md)/s$	1.º e 2.º coeficientes de Pearson
	$K = (Q_3 - Q_1) / [2(P_{90} - P_{10})]$	Curtose percentílica; referência 0,263 — e a relação é invertida
Outliers	$Q_1 - 1,5 \cdot AIQ \mid Q_3 + 1,5 \cdot AIQ$	Limites do boxplot
	$y = x + a$	Dispersão não muda ; posição desloca
	$y = b \cdot x$	$s \rightarrow b s$; $s^2 \rightarrow b^2 s^2$; CV não muda
Probabilidade	$P(A^c) = 1 - P(A)$	Complementar
	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	Regra da adição
	$P(A B) = P(A \cap B) / P(B)$	Condicional; exige $P(B) > 0$
	$P(A \cap B) = P(A B) \cdot P(B)$	Regra do produto
	$P(A \cap B) = P(A) \cdot P(B)$	Independência (definição)
	$P(A) = \Sigma P(A B_i) \cdot P(B_i)$	Probabilidade total (exige partição)
	$\text{Var}(X \pm Y) = \text{Var}X + \text{Var}Y \pm 2\text{Cov}$	Independentes $\Rightarrow$ variâncias somam nos dois casos

BLOCO	FÓRMULA	LEITURA / CUIDADO
Amostragem	$f = n/N$	Fração amostral — denominador é a população
	$\text{Var}(\bar{x}) = \sigma^2/n$	AAS com reposição
	$\text{Var}(\bar{x}) = (\sigma^2/n) \cdot (N-n)/(N-1)$	AAS sem reposição (FCPF)
	$\text{e.p.}(\hat{p}) = \sqrt{[p(1-p)/n]} \leq 0,5/\sqrt{n}$	Erro padrão de proporção
	$k = N/n$	Intervalo da amostragem sistemática
	$n_h = n \cdot N_h S_h / \sum N_i S_i$	Neyman; proporcional é o mesmo sem o S_h

4.2 As 40 frases que valem ponto

DESCRITIVA — VARIÁVEIS E TABELAS

1. Média não existe para variável qualitativa; **moda existe para qualquer variável**.
2. Mediana existe para ordinal, mas não para nominal.
3. Número não é sinônimo de quantitativa: CNPJ e CEP são **nominais**.
4. Histograma é para quantitativa e tem barras **justapostas**; barras separadas são de qualitativa.
5. Em classes de larguras diferentes, é a **área** da barra que representa a frequência, não a altura.
6. A ogiva é **sempre não decrescente**; o polígono de frequências, não.
7. Ramo-e-folhas **preserva** os dados originais; o histograma, não.
8. A frequência relativa acumulada é a régua das separatrizes: 25% → Q_1 , 50% → mediana, 75% → Q_3 .

DESCRITIVA — POSIÇÃO

9. A soma dos desvios em relação à média é **zero**.
10. A média minimiza a soma dos **quadrados**; a mediana, a soma dos **módulos**.
11. Outlier desloca a **média**; não desloca mediana nem moda.
12. Média de médias só é a média geral se os grupos tiverem o mesmo tamanho.
13. A média não precisa ser um valor observado nem sequer possível.
14. Mediana é **posição no rol**, nunca a média dos valores extremos.
15. Assimetria positiva: **moda < mediana < média**. Negativa: o inverso. A média foge para o lado da cauda.
16. $Q_2 = D_5 = P_{50} = \text{mediana}$.
17. Quartil isolado é **posição**; diferença entre quartis é **dispersão**.

DESCRITIVA — DISPERSÃO E FORMA

18. Somar constante **não altera** dispersão alguma; multiplicar por b multiplica o desvio padrão por $|b|$ e a variância por b^2 .
19. O dobro no desvio padrão é o **quádruplo** na variância.
20. Variância amostral divide por $n - 1$, para ser estimador não viesado.
21. A variância amostral é sempre **maior** que a populacional calculada sobre os mesmos dados.
22. Desvio padrão nunca é negativo; é zero se e somente se todos os valores forem iguais.
23. O CV é o único adimensional — é ele que compara dispersões de unidades diferentes.
24. Assimetria e curtose são medidas de **forma**: nunca de posição, nunca de dispersão.
25. Coeficiente de momento: leptocúrtica > 3 , mesocúrtica $= 3$, platicúrtica < 3 .
26. Coeficiente **percentílico** de curtose: a relação é **invertida** — maior que 0,263 é platicúrtica.

27. Boxplot mostra a **mediana**, não a média; a caixa contém os 50% centrais.

28. Outlier: fora de $Q_1 - 1,5 \cdot \text{AIQ}$ ou $Q_3 + 1,5 \cdot \text{AIQ}$.

PROBABILIDADE

29. Os axiomas são **três**: não negatividade, normalização e aditividade. O resto é teorema.

30. Mutuamente exclusivos com probabilidades positivas $\Rightarrow$ **dependentes**.

31. Independentes $\Rightarrow$ os complementares também são independentes.

32. Condicionar em evento independente **não muda** a probabilidade.

33. Independência **dois a dois** não é independência **mútua**.

34. Probabilidade total exige **partição** — exclusivos e exaustivos.

35. Variável contínua: $P(X = a) = 0$, $\leq$ equivale a $<$.

36. Probabilidade zero não implica evento impossível (caso contínuo).

37. Independência $\Rightarrow$ correlação zero; correlação zero **não** $\Rightarrow$ independência.

AMOSTRAGEM

38. Fração amostral é n/N — o denominador é a **população**.

39. AAS **sem** reposição: observações **não** independentes, e a variância cai pelo fator $(N-n)/(N-1)$.

40. Estratificada: sorteiam-se **elementos** e **todos** os estratos entram. Conglomerados: sorteiam-se **grupos** e nem todos entram.

BÔNUS — CINCO FRASES DE AMOSTRAGEM QUE VALEM TANTO QUANTO AS QUARENTA

- Estrato: homogêneo **por dentro**. Conglomerado: heterogêneo por dentro, parecido com os outros.
- Neyman manda amostra para onde há **variabilidade**, não para onde há gente.
- Alocação **proporcional** é autponderada; **uniforme** e **ótima** não são.
- Aumentar n reduz o erro **amostral**; não reduz o erro **não amostral**.
- Amostragem por **cotas** não é estratificada: dentro do grupo, a escolha é por conveniência.

4.3 Radar de palavras — as expressões que denunciam o item

SE O ITEM DISSER...	DESCONFIE PORQUE...	TENDÊNCIA
"sempre", "nunca", "necessariamente", "em qualquer caso", "somente"	Estatística é cheia de condições (independência, continuidade, n grande, partição)	ERRADO
"pois", "já que", "uma vez que", "visto que", "porque"	Estrutura afirmação + justificativa: as duas partes precisam ser verdadeiras e o nexos sustentar	Testar as três coisas
"mutuamente exclusivos, logo independentes"	É exatamente o contrário	ERRADO
"correlação nula, logo independentes"	Correlação zero exclui só relação linear	ERRADO
"a média da variável [qualitativa]"	Média não se aplica a categórica	ERRADO

SE O ITEM DISSER...	DESCONFIE PORQUE...	TENDÊNCIA
"o boxplot indica que a média..."	Boxplot exibe a mediana	ERRADO
"o desvio padrão é a variância"	Falta a raiz — e a unidade denuncia	ERRADO
"aumentar a amostra reduz o erro não amostral"	Só reduz o erro amostral	ERRADO
"selecionaram-se grupos, logo é conglomerado"	Estratificada também trabalha com grupos — a diferença é o que se sorteia	Verificar
"amostragem por conveniência / cotas / julgamento / bola de neve"	São não probabilísticas ; não estão no rol do edital de AL	Verificar
"a fração amostral é n dividido pelo tamanho da amostra"	O denominador é a população	ERRADO
Um número redondo demais (0,1; 10%; 0,5)	Costuma ser um dado do enunciado reaproveitado no lugar errado	Refazer a conta
Comparação com limiar de casa decimal ("superior a 17,5%")	O valor foi escolhido para ficar a milésimos da resposta	Calcular até o fim
Definição literal e completa de um instituto	O CEBRASPE também escreve itens certos ; nem tudo é pegadinha	CERTO

4.4 Método de resolução em quatro passos

1. **Classifique o item** em um dos três eixos (descritiva, probabilidade, amostragem) e, dentro dele, no subtema. Só isso elimina metade dos erros: quem sabe que está diante de "estratificada × conglomerados" não confunde a resposta. No bloco do TCE/RN 2025, essa classificação sozinha entregava cinco itens.
2. **Isole a afirmação.** Havendo conectivo causal, separe conclusão e justificativa e julgue cada uma isoladamente, depois o nexo. Se qualquer das três verificações falhar, o item é ERRADO.
3. **Faça a conta mínima.** Em geral é uma linha: uma raiz, uma multiplicação de duas probabilidades, uma soma ponderada, uma interpolação. **Se a conta está ficando longa, você entendeu o enunciado errado** — releia antes de continuar calculando.
4. **Compare com o limiar exato** do enunciado ("superior a", "inferior a", "igual ou superior a", "no máximo"). Vários gabaritos giram sobre o sinal: $0,1183 > 0,11$ e $17,1\% < 17,5\%$ são itens inteiros decididos na terceira casa decimal.

ROTEIRO DE ESTUDO SUGERIDO — 30 HORAS

ETAPA	CONTEÚDO	HORAS
1	Tópico 1 completo, refazendo o exemplo mestre à mão	10
2	Tópico 2, com ênfase em condicional, independência e probabilidade total	7
3	Tópico 3, memorizando o quadro estratificada × conglomerados	7
4	Refazer as 62 questões deste material, cronometrado	4
5	Parte 4 — formulário, 40 frases e radar	2
Total		30

META REALISTA PARA OS 10 ITENS

Com o programa fechado deste edital, **7 a 8 marcações seguras** são plenamente alcançáveis com cerca de 30 horas de estudo bem dirigido. E, pela aritmética da seção 0.2, **7 acertos com 3 brancos (nota 7) valem mais do que 10 marcações com 3 erros (nota 4)**. Deixar em branco o que não se sabe não é concessão: **é parte da técnica**.

Metodologia. Todo o acervo de provas e gabaritos foi obtido diretamente do repositório oficial do CEBRASPE (cdn.cebraspe.org.br). Foram baixados 582 arquivos de 46 concursos — 291 cadernos de provas objetivas e 291 gabaritos definitivos —, convertidos em texto e varridos automaticamente pelos blocos de Estatística e Probabilidade. Os 11 blocos localizados foram lidos item a item; cada gabarito citado foi conferido contra o gabarito *definitivo* do respectivo concurso e cada resultado numérico foi recalculado de forma independente. As justificativas identificadas como "justificativa oficial" são transcrições dos documentos de gabarito comentado publicados pela própria banca (SEEC/DF 2019 e TC/DF 2024). Conteúdo programático conforme o item 14.2.3; formato e critérios de avaliação conforme os itens 8.2, 8.11.2, 8.11.4 e 8.11.5; datas conforme o Anexo I — todos do Edital nº 1 – SEFAZ/AL, de 24 de agosto de 2026.